Directrices para la Evaluación de Impacto Interseccional

Un marco para evaluar los impactos interseccionales de los sistemas de inteligencia artificial específicamente en modelos de lenguaje y visión

INTER VISIONS

Co-funded by the European Union

Proyecto: InterVisions (101214711)
CERV-2024-CHAR-LITI-CHARTER

Estas directrices han sido elaboradas por el consorcio InterVisions (ALIA-Donestech, Computer Vision Center y Diputació de Barcelona), con las aportaciones de un Grupo de Trabajo de las Directrices específico y de un Consejo Asesor. Los agradecimientos completos se encuentran en la página 25.

INTER VISIONS

Co-funded by the European Union

Financiado por la Unión Europea. Las opiniones y puntos de vista expresados solo comprometen a su(s) autor(es) y no reflejan necesariamente los de la Unión Europea o los de la Agencia Ejecutiva Europea de Educación y Cultura (EACEA). Ni la Unión Europea ni la EACEA pueden ser considerados responsables de ellos.

ÍNDEX

Introducción **4**
Contexto: modelos multimodales y fundacionales 4
La necesidad de una Evaluación de Impacto Interseccional 4
Finalidad y doble objetivo 5
Relación con el Reglamento de IA de la UE y la FRIA 6

1. Posicionamiento y fundamentos conceptuales **7**
1.1. Una revisión crítica de los marcos existentes 7
1.2. La interseccionalidad como marco analítico 9
1.3. Enfoque específico: sistemas de recuperación basados en CLIP 10

2. Principios normativos y metodológicos **11**
2.1. Principios sustantivos y procedimentales 11
2.2. Objetivos de las directrices 14
2.3. Público destinatario 14

3. El marco de la Evaluación de Impacto Interseccional (EII) **15**
3.1. Calendario y uso de la EII 15
3.2. Dimensiones analíticas 16
3.3. Áreas del análisis 17
3.4. La Matriz como herramienta operativa 18
3.5. Del diagnóstico a la toma de decisiones 18

Glosario de términos clave **20**
Referencias **22**
Anexo A: El marco de la EII **24**
Autoría y agradecimientos **25**

Cómo utilizar este documento: esta guía está pensada para ser modular. No es necesario recorrer todas las secciones de forma secuencial. Según vuestro rol y la fase de desarrollo, utilizad el índice para ir directamente a la sección pertinente. El marco de la EII (sección 3) es el núcleo operativo; la Matriz (anexo A) ofrece el banco detallado de preguntas para cada fase y dimensión analítica.

Introducción

Contexto: modelos multimodales y fundacionales

Los modelos fundacionales multimodales, sistemas de IA entrenados con combinaciones a gran escala de texto, imágenes y otras modalidades de datos, plantean **retos específicos y poco examinados para la evaluación de los derechos fundamentales**. Su escala, su complejidad arquitectónica y su capacidad para desplegarse en múltiples contextos posteriores hacen que los daños sean a menudo difusos, acumulativos y difíciles de atribuir a una única decisión de diseño o a un único punto de fallo.

Tal como documentan el proyecto InterVisions y una literatura académica creciente, **los enfoques existentes de auditoría de sesgos y de evaluación de la equidad tienden a ser técnicamente limitados**. A menudo evalúan categorías demográficas aisladas en lugar de su intersección, y rara vez captan cómo las desigualdades estructurales se reproducen a través de la curación de datos, las decisiones de diseño y las condiciones de despliegue. Los modelos de visión y lenguaje como CLIP, que sustentan la recuperación de imágenes, la ordenación de contenidos y muchas aplicaciones generativas, son especialmente susceptibles a estas limitaciones, ya que heredan sesgos de representación de datos web a gran escala y los distribuyen masivamente a través de los sistemas derivados.

La necesidad de una Evaluación de Impacto Interseccional

Estas limitaciones hacen necesarias metodologías capaces de integrar el análisis técnico con el contexto social, el conocimiento participativo y las consideraciones basadas

en derechos. Una auditoría puramente técnica no puede hacer aflorar las formas en que un sistema de IA puede invisibilizar a determinadas comunidades, asignarlas a categorías estereotipadas o exponerlas a daños desproporcionados. Una Evaluación de Impacto Interseccional (EII o IIA, por sus siglas en inglés) está diseñada para cubrir este vacío.

La EII ofrece una forma estructurada de identificar quién puede verse afectado por un sistema de IA, cómo pueden surgir o intensificarse los riesgos y las desigualdades a través de categorías sociales que se entrecruzan, y qué medidas pueden ser necesarias para prevenir, mitigar o reparar los impactos adversos a lo largo de todo el ciclo de vida del sistema. No lo hace como un ejercicio puntual de cumplimiento normativo, sino como un **proceso continuo y participativo de escrutinio y rendición de cuentas.**

Finalidad y doble objetivo

Estas directrices proporcionan una **metodología práctica** para llevar a cabo una EII en el contexto de los sistemas de IA, en particular de los **modelos multimodales y fundacionales**. Están pensadas para apoyar a las personas profesionales en:

→ Identificar y analizar de forma sistemática los impactos y las vulnerabilidades interseccionales a lo largo de todo el ciclo de vida del sistema de IA.

→ Integrar perspectivas técnicas, sociales y participativas en un proceso de evaluación coherente.

→ Traducir los resultados en decisiones concretas de prevención, mitigación y reparación.

El marco tiene un **doble objetivo:**

→ **Aplicación interna:** ofrecer una guía práctica para llevar a cabo el análisis interseccional dentro del proyecto InterVisions, aplicable a sus estructuras de gobernanza, prácticas de datos, herramientas de auditoría de sesgos, talleres participativos y benchmark técnico.

→ **Replicabilidad:** ofrecer un enfoque metodológico adaptable a otros proyectos con sistemas de IA multimodales o, de forma más amplia, a cualquier sistema de IA cuyo diseño y despliegue puedan producir impactos sociales diferenciados.

Al ofrecer un marco estructurado pero adaptable, las directrices pretenden que las evaluaciones de impacto vayan más allá del cumplimiento puramente procedimental y contribuyan, en cambio, a un desarrollo y un despliegue de la IA más responsables, justos y alineados de forma fundamental con los derechos.

Importante: estas directrices no prescriben una única respuesta correcta para cada pregunta planteada. No son una herramienta de puntuación. Su finalidad es estimular la reflexión crítica, hacer aflorar lo que no se ha tenido en cuenta, apoyar la toma de decisiones sustantivas y promover la acción transformadora. Estas directrices no tienen por objetivo emitir un certificado de cumplimiento.

Relación con el Reglamento de IA de la UE y la FRIA

Esta Evaluación de Impacto Interseccional constituye una contribución a la **evaluación de impacto relativa a los derechos fundamentales (FRIA, por sus siglas en inglés)** exigida por el artículo 27 del Reglamento de IA de la UE. Si bien el artículo 27 se dirige formalmente a los responsables del despliegue de sistemas de alto riesgo, el marco de la EII se aplica a los sistemas de IA de forma más amplia, incluidos los modelos fundacionales y los sistemas multimodales, como los sistemas de recuperación basados en CLIP, que, aunque no estén necesariamente clasificados como de alto riesgo, producen un impacto social significativo y riesgos interseccionales que requieren una evaluación estructurada. Las organizaciones que realicen una FRIA pueden utilizar la Matriz EII para fundamentar varios de los elementos que el artículo 27 exige documentar a los responsables del despliegue, como las categorías de personas afectadas, los riesgos específicos de daño, las medidas de supervisión humana y los mecanismos de reclamación; esta correspondencia podrá perfeccionarse a medida que se disponga de orientación sobre la FRIA.

También se basa metodológicamente en la **evaluación de impacto relativa a la protección de datos (EIPD)** establecida por el Reglamento General de Protección de Datos (RGPD). Sin embargo, va más allá de estos requisitos: **adopta un enfoque interseccional y feminista que los marcos regulatorios actuales todavía no han integrado, y amplía el alcance del análisis a las desigualdades estructurales, la justicia ambiental y la gobernanza participativa.**

Esta evaluación se sitúa, además, dentro del **marco de derechos humanos del Consejo de Europa para la gobernanza de la IA**. Se fundamenta en el Convenio Marco sobre inteligencia artificial y derechos humanos, democracia y Estado de derecho (STCE n.º 225, 2024), el primer tratado internacional vinculante sobre IA, que obliga a los Estados parte a garantizar que los sistemas de IA sean compatibles con los derechos humanos, la democracia y el Estado de derecho a lo largo de todo su ciclo de vida. También se inspira en dos recomendaciones del Consejo de Europa directamente relevantes para la orientación feminista e interseccional de esta evaluación: la Recomendación CM/Rec(2026)1 sobre igualdad e inteligencia artificial, que orienta a los Estados a prevenir la discriminación por motivos como el género, la raza y la SOGIESC (orientación sexual, identidad y expresión de género y características sexuales) a lo largo de todo el ciclo de vida de la IA; y la Recomendación CM/Rec(2026)2 sobre la rendición de cuentas por la violencia facilitada por la tecnología contra las mujeres y las niñas, a la que recurre esta evaluación al examinar cómo los sistemas de IA pueden facilitar, amplificar o no prevenir la violencia de género facilitada por la tecnología.

1. Posicionamiento y fundamentos conceptuales

1.1. Una revisión crítica de los marcos existentes

Diversos marcos consolidados abordan la evaluación de los impactos de los sistemas de IA. La EII se basa en sus aportaciones a la vez que aborda sus limitaciones relevantes para el análisis interseccional y feminista:

Marco	Principios clave	Principal limitación para la EII	Aplicabilidad
FRIA (Reglamento de IA de la UE, art. 27)	Evaluación obligatoria de impacto relativa a los derechos fundamentales para sistemas de IA de alto riesgo; abarca la dignidad, la no discriminación, la privacidad y la tutela judicial efectiva.	Procedimental y mínima: define el alcance pero apenas ofrece orientación metodológica; sin marco de interseccionalidad.	Toda la UE; obligatoria para los responsables del despliegue de IA de alto riesgo que sean organismos de derecho público, entidades privadas que presten servicios públicos o empresas que utilicen IA para la calificación crediticia o la fijación de precios de seguros de vida o salud (a raíz del Ómnibus Digital sobre IA, la aplicación se ha aplazado hasta diciembre de 2027).[1]
EIPD (RGPD)	Evaluación estructurada de los riesgos de los datos; privacidad y protección de datos desde el diseño; obligatoria para actividades de tratamiento de alto riesgo.	Alcance limitado: solo protección de datos; no aborda derechos más amplios ni la representación.	UE/EEA (*European Economic Area*), con alcance extraterritorial; obligatoria para cualquier responsable del tratamiento, del sector público o privado, cuyo tratamiento pueda entrañar un alto riesgo para los derechos de las personas.

1- Las normas para los sistemas de IA de alto riesgo integrados en productos regulados (anexo I) disponen ahora de un período transitorio ampliado hasta el 2 de agosto de 2028, y las normas para los casos de uso de alto riesgo en ámbitos sensibles (anexo III, incluidas la calificación crediticia y la fijación de precios de seguros) se amplían hasta el 2 de diciembre de 2027. Estos cambios ya no son solo un acuerdo político: adquirieron efectos jurídicos como Reglamento (UE) 2026/1744 («Ómnibus Digital sobre IA»), que entró en vigor el 27 de julio de 2026. Disponible en: https://digital-strategy.ec.europa.eu/en/library/digital-omnibus-ai-regulation-proposal

Marco	Principios clave	Principal limitación para la EII	Aplicabilidad
Canadá - Directiva sobre la toma de decisiones automatizada (DADM)	Directiva federal que exige una evaluación obligatoria de impacto algorítmico (AIA) antes de desplegar sistemas gubernamentales de decisión automatizada (ADS); los resultados de la AIA determinan uno de cuatro niveles de riesgo, cada uno con salvaguardas proporcionadas.	Limitada a los ADS federales y centrada en la paridad demográfica sin análisis interseccional.	Solo el gobierno federal canadiense; obligatoria para los ADS de los departamentos que toman o apoyan decisiones administrativas que afectan a la ciudadanía (excluida la seguridad nacional).
AI HLEG / ALTAI	Siete requisitos para una IA fiable (supervisión, solidez, privacidad, transparencia, equidad, bienestar, rendición de cuentas); lista de verificación práctica ampliamente utilizada en la industria europea.	Atención moderada a la interseccionalidad; sin análisis estructural del poder; voluntaria; enfoque de equidad de un solo eje.	UE; autoevaluación voluntaria para desarrolladores y responsables del despliegue de IA de todos los sectores, más utilizada en la industria.
Recomendación de la UNESCO sobre la ética de la IA + herramienta EIA	Un estándar normativo global con cuatro valores centrales (derechos humanos, inclusión, sostenibilidad, pluralismo); la evaluación estructurada EIA abarca la delimitación del alcance y una revisión basada en principios.	Más adecuada para la revisión ex ante de las contrataciones que para la auditoría algorítmica continuada o las pruebas técnicas de sesgos, y no aborda el daño de representación específico de la IA multimodal.	Global; instrumento normativo no vinculante dirigido a los gobiernos y responsables políticos de los 194 Estados miembros de la UNESCO; la herramienta EIA la utilizan equipos de proyectos de IA y comunidades afectadas para evaluar los impactos de los sistemas.
Modelo PIO (Observatori d'Ètica en IA de Catalunya)	Un marco y una herramienta de autoevaluación para medir la alineación ética de los sistemas de IA que incluye siete principios clave (transparencia, equidad, seguridad, rendición de cuentas, privacidad, autonomía, sostenibilidad).		Cataluña (regional); autoevaluación abierta y voluntaria para organizaciones del sector público y privado, desarrollada por el OEIAC en el marco de la estrategia de IA de la Generalitat de Catalunya y armonizada con el Reglamento de IA de la UE.
Alan Turing Institute - Guía de ética y seguridad de la IA	Guía de ética y seguridad de la IA orientada al sector público que introduce una «plataforma ética» para diseñar y desplegar la IA de manera responsable. Pone un fuerte énfasis en la gobernanza basada en procesos (ética del flujo de trabajo, roles, documentación).	Diseñada principalmente para contextos del sector público del Reino Unido y no aborda adecuadamente la interseccionalidad ni los daños de representación.	Sector público del Reino Unido; orientación voluntaria para departamentos gubernamentales y personal funcionario que diseña y despliega IA.

Marco	Principios clave	Principal limitación para la EII	Aplicabilidad
HRIA (Human Rights Impact Assessment - Evaluación de Impacto en Derechos Humanos)	Implicación sólida de las personas titulares de derechos; lógica de diligencia debida; identificación de los grupos afectados; mecanismos de reparación y de queja.	Operacionalización limitada para sistemas técnicos de IA; rara vez adaptada a contextos algorítmicos o multimodales.	Intersectorial y global; utilizada por empresas e instituciones, fundamentada en los Principios Rectores de las Naciones Unidas sobre las Empresas y los Derechos Humanos; voluntaria / basada en la diligencia debida.
Herramientas de equidad - *fariness* (e.g. Aequitas, Fairlearn)	Operacionalizan métricas cuantitativas de equidad; detección automatizada de disparidades de rendimiento entre grupos demográficos.	Análisis demográfico de un solo eje; sin componente participativo; el enfoque técnico se desconecta de los derechos y del contexto estructural.	Independientes del sector; bibliotecas técnicas de código abierto para desarrolladores de aprendizaje automático y científicos de datos; voluntarias.
EIA (Environmental Impact Assessment - Evaluación de Impacto Ambiental)	Análisis estructurado de los daños a lo largo del ciclo de vida; identificación de medidas de mitigación; principios de precaución y proporcionalidad.	No aborda las categorías sociales, los derechos, la interseccionalidad ni el daño de representación.	Prevista por ley en muchas jurisdicciones; obligatoria para promotores de proyectos y autoridades públicas que aprueban grandes proyectos (ámbito ambiental, no relacionado con la IA, incluida como análogo metodológico).

1.2. La interseccionalidad como marco analítico

La interseccionalidad, teorizada originalmente por Kimberlé Crenshaw (1989) para comprender los efectos combinados de la raza y el género en contextos jurídicos, constituye el eje analítico de esta evaluación. En el contexto de los sistemas de IA, **la interseccionalidad implica reconocer que la exposición al daño, la invisibilidad y la exclusión no se distribuyen de manera uniforme dentro de ninguna categoría social única**. Al contrario, las personas experimentan los sistemas de IA a través de la interacción simultánea del género, la raza, la etnia, la clase, la discapacidad, la neurodiversidad, la edad, la sexualidad, la situación migratoria y otras dimensiones de la posición social.

El marco de Crenshaw identifica identidades superpuestas y pone de relieve las formas en que los sistemas de poder y los dispositivos institucionales que se entrecruzan producen formas particulares de desventaja y exclusión.

A partir de esta idea, Patricia Hill Collins y Sirma Bilge (2016), basándose en el concepto anterior de Collins de «matriz de dominación», desarrollan **la interseccionalidad como un análisis estructural** de cómo el racismo, el capitalismo, el heteropatriarcado, el colonialismo y el capacitismo, entre otros, se organizan a través de las instituciones sociales y se reproducen a través de las prácticas cotidianas, incluidas las tecnológicas. Desde esta perspectiva, no importa solo quién sufre el daño, sino qué dispositivos estructurales lo hacen posible, previsible y a menudo invisible.

Esta distinción tiene consecuencias para la EII: significa que la evaluación no puede limitarse a identificar qué grupos demográficos están infrarrepresentados o mal clasificados. Debe preguntar **qué sistemas de poder, incrustados en las prácticas de recogida de datos, las decisiones de contratación, las culturas organizativas y las lógicas de mercado, se reproducen a través del diseño y el despliegue del sistema de IA**. Charting Pathways (2024), que también se basa en D'Ignazio y Klein (2019), Benjamin (2019) y Ovalle et al. (2023) -véanse las referencias-, operacionaliza este enfoque

estructural trazando los canales por los que las desigualdades sistémicas se trasladan a los sistemas de IA: desde las condiciones del trabajo de datos hasta la concentración del poder de decisión en el desarrollo tecnológico.

Este marco opera en tres niveles:

→ **Micro (individual):** ¿cómo representa, o representa mal, el sistema a las personas individuales a través de categorías que se entrecruzan? ¿La experiencia de quién se hace visible, y la de quién se borra o se estereotipa?

→ **Meso (institutional)**: ¿qué dinámicas organizativas, comerciales y políticas condicionan cómo se construye y se despliega el sistema? ¿Cómo reproducen o cuestionan las culturas institucionales las desigualdades estructurales?

→ **Macro (poder estructural)**: ¿cómo se relaciona el sistema con los sistemas de poder más amplios -capitalismo, colonialismo, heteropatriarcado, capacitismo-? ¿Los reproduce o los cuestiona?

En la práctica, esto significa que para la EII no bastan las métricas de diversidad demográfica. Tal como señaló el grupo de trabajo de InterVisions, **la representación demográfica no garantiza la conciencia política de las relaciones de poder**. La evaluación debe examinar si **los patrones interseccionales de desventaja se identifican, se abordan y se cuestionan activamente**, y no solo si se reconocen.

1.3. Enfoque específico: sistemas de recuperación basados en CLIP

Dentro del proyecto InterVisions, la EII se aplica específicamente a los modelos de visión y lenguaje basados en CLIP utilizados en tareas de recuperación de imágenes. Estos sistemas tienen una relevancia interseccional particular porque:

→ Se entrenan con **datos web a gran escala** que codifican sesgos sociales existentes tanto en el lenguaje como en las imágenes (Hamidieh et al., 2024).

→ Funcionan como **componentes de uso general** que heredan las aplicaciones posteriores, de modo que las decisiones de representación se propagan ampliamente.

→ Las tareas de recuperación determinan directamente **qué se hace visible, relevante o localizable**, con efectos concretos en el acceso a la información y la representación cultural.

→ La investigación previa muestra que **conceptos genéricos** como «persona» tienden a asociarse con sujetos blancos, de mediana edad, sin discapacidad y de apariencia masculina, mientras que otros grupos están infrarrepresentados o vinculados a contextos estereotipados o marginalizados (Agarwal et al., 2021 y Hausladen et al., 2025).

→ **Medir el sesgo en estos sistemas es en sí mismo problemático:** requiere etiquetar a las personas según categorías demográficas percibidas (p. ej. género, raza, edad, discapacidad), lo que conlleva el riesgo de caer en categorizaciones esencialistas (D'Ignazio & Klein, 2020) y en la asignación errónea de género o categoría (*misgendering o miscategorisation*) (Scheuerman et al., 2019); además, cuanto más finas son las interseccionalidades consideradas, menores son las muestras, lo que limita la fiabilidad de las métricas cuantitativas.

La falta de consenso en la literatura sobre equidad acerca de cómo medir o resolver estos sesgos hace todavía más esencial la dimensión participativa e interseccional de este marco.

2. Principios normativos y metodológicos

A partir del **contexto regulatorio** descrito en la introducción (cf. artículo 27 del Reglamento de IA de la UE; RGPD), esta sección expone los derechos fundamentales y los principios normativos que guían la EII en los sistemas de IA, incluidos los modelos multimodales y fundacionales más allá de la categoría de alto riesgo. Su finalidad es identificar y evaluar los posibles impactos sobre los derechos fundamentales, determinar qué personas y grupos pueden verse afectados (incluidas las que se encuentran en situación de vulnerabilidad) y definir las medidas adecuadas para prevenir o mitigar los impactos adversos.

Por lo tanto, la evaluación debería considerar, como mínimo, los siguientes derechos fundamentales, tal como los protege la **Carta de los Derechos Fundamentales de la Unión Europea**: dignidad e integridad personal (artículos 1 y 3); privacidad y protección de datos (artículos 7 y 8); libertades y participación en la sociedad (artículos 11, 12 y 16); igualdad y no discriminación (artículos 20, 21 y 23); protección de los grupos vulnerables (artículos 24, 25 y 26); y garantías procesales y tutela efectiva (artículos 41, 47 y 48).

Para garantizar la protección efectiva de los derechos fundamentales mencionados en el contexto de sistemas de IA que pueden producir impactos sociales diferenciados, la Evaluación de Impacto Interseccional se guía por los **principios sustantivos y procedimentales que se describen a continuación.** Dos de estos principios (la perspectiva feminista e interseccional, y el cuidado) son transversales: deben informar no solo el principio que les es propio, sino también cómo se diseñan, a lo largo de toda la evaluación, la definición del problema, las prácticas de datos, la participación, la metodología, las pruebas y la mitigación.

2.1. Principios sustantivos y procedimentales

La EII se rige por once principios. No son compromisos abstractos: cada uno debe operacionalizarse mediante decisiones concretas sobre cómo se diseña y se lleva a cabo la evaluación.

1.
Referentes normativios y técnicos

La evaluación debe fundamentarse en el derecho internacional y europeo de los derechos humanos como marco normativo principal. También debe tener en cuenta referentes técnicos y regulatorios, como los estándares de gestión de riesgos de la IA, los requisitos de gobernanza de datos y las métricas de equidad reconocidas, de modo que el cumplimiento técnico apoye la protección de los derechos fundamentales, y no la sustituya.

2.
Perspectiva feminista e interseccional

La evaluación adopta un enfoque feminista e interseccional que examina cómo las infraestructuras digitales, las prácticas de datos y la toma de decisiones automatizada pueden reproducir, amplificar o no prevenir las desigualdades estructurales, la discriminación y la violencia. El género, la raza, la clase, la discapacidad, la neurodiversidad, la edad, la sexualidad, la situación migratoria y otros factores que se entrecruzan condicionan tanto la exposición al daño como el acceso a la protección y a la reparación. Exige prestar atención a la violencia de género facilitada por la tecnología y a los sistemas de IA que difuminan la frontera entre lo público y lo privado, con una sensibilidad especial hacia el contenido íntimo (cf. Recomendación CM/Rec(2026)2 del Consejo de Europa).

3.
Cuidado

El cuidado es un principio transversal, no limitado a una sola fase. Exige atención al trabajo de cuidados no remunerado y a la reproducción social, a menudo invisibles en las evaluaciones técnicas, así como al bienestar de las personas participantes y probadoras, que deben contar con salvaguardas emocionales y psicológicas cuando trabajan con contenido violento o sexualizado. El cuidado debe integrarse a lo largo de todo el proceso de la EII y no debe tratarse como algo opcional.

4.
Participación

Debe garantizarse la participación significativa de las personas titulares de derechos, incluidas las afectadas directa e indirectamente, en todas las fases de la evaluación. La participación debe ser accesible, sensible al contexto e iniciarse pronto, de modo que permita una implicación sostenida en las cuestiones relativas al uso de los datos, el diseño del sistema y los posibles impactos. La diversidad demográfica por sí sola no constituye una participación significativa; hay que prestar atención a las dinámicas de poder dentro de los grupos participantes y entre ellos.

5.
Empoderamiento

El proceso debe fortalecer la capacidad de las personas y las comunidades para comprender y cuestionar los sistemas automatizados que les afectan. Esto incluye facilitar el acceso a explicaciones claras, el apoyo en alfabetización digital y el ejercicio efectivo de los derechos de protección de datos y otros derechos digitales.

6. Transparencia y gobernanza de datos

La evaluación debe garantizar la transparencia no solo de su propio proceso, sino también del funcionamiento del sistema de IA, de sus fuentes de datos y de sus estructuras de gobernanza, preservando al mismo tiempo la privacidad. Debe proporcionarse información clara y accesible sobre la recogida de datos, la lógica del tratamiento, la gestión de riesgos y los mecanismos de supervisión.

7. Rendición de cuentas

Deben asignarse responsabilidades claras para identificar, prevenir y abordar los impactos adversos, con el respaldo de recursos y conocimientos adecuados. La propia metodología de evaluación debe quedar sometida a escrutinio y a revisión periódica, y debe funcionar como un mecanismo sustantivo de protección de derechos, no como un ejercicio de cumplimiento formalista o de mero trámite.

8. Alcance y gravedad de los impactos

La evaluación debe identificar los impactos reales y potenciales causados por el sistema de IA o vinculados a él, incluidos los efectos acumulativos y heredados. Los impactos deben evaluarse según su gravedad: alcance (cuántas personas se ven afectadas), magnitud (con qué gravedad), irreversibilidad (si el daño es reparable), vulnerabilidad de los grupos afectados e interdependencia de los derechos.

9. Mitigación y acceso a la reparación

Deben abordarse todos los impactos adversos identificados, priorizando los más graves. Las medidas deben seguir una jerarquía de prevención, mitigación y reparación. Deben garantizarse mecanismos de queja accesibles y formas adecuadas de reparación, incluida la reparación material y simbólica.

10. Sostenibilidad ambiental

La evaluación debe examinar las implicaciones ambientales del sistema de IA a lo largo de todo su ciclo de vida: consumo energético, infraestructura de hardware, emisiones de carbono y extracción de materiales. Los daños ambientales deben analizarse en relación con sus consecuencias para los derechos humanos, especialmente para las comunidades afectadas de forma desproporcionada por la injusticia ambiental.

11. Poder estructural, extractivismo y gobernanza democrática

La evaluación debe valorar si el sistema de IA refuerza la concentración económica, el extractivismo de datos o las asimetrías estructurales de poder tecnológico. Hay que prestar atención a la salvaguarda de los valores democráticos, a la prevención de una concentración indebida de influencia y a garantizar que el despliegue de la IA no socave el pluralismo, la justicia social ni la autodeterminación colectiva.

2.2. Objetivos de las directrices

Estas directrices tienen por objetivo:

→ Garantizar **la equidad, la inclusión y la rendición de cuentas** en el diseño, el desarrollo y el despliegue de los sistemas de IA.

→ Proteger **la privacidad y los datos personales** como derechos fundamentales a lo largo de todo el ciclo de vida de la IA.

→ Promover la **justicia ambiental** evaluando la huella de recursos y emisiones de la IA en relación con los derechos humanos.

→ Fomentar la **autorreflexividad** entre las personas profesionales, alentando un examen continuo de la posicionalidad y de las dinámicas de poder dentro de los equipos de proyecto.

→ Facilitar la transferencia de **conocimiento interseccional** entre disciplinas y contextos de proyecto.

2.3. Público destinatario

Estas directrices se dirigen a cualquier persona implicada en auditorías algorítmicas interseccionales, diseño participativo de IA o gobernanza responsable de la IA, especialmente cuando intervienen sistemas multimodales. Esto incluye, entre otros: **entidades financiadoras y titulares de proyectos** que establecen las condiciones del desarrollo de la IA; **desarrolladores de IA, personal investigador y equipos técnicos** que construyen o evalúan sistemas; **personas facilitadoras de talleres e investigadoras comunitarias** que conducen procesos participativos; e **instituciones públicas, organismos reguladores y organizaciones de la sociedad civil** implicadas en la supervisión o la contratación de la IA.

Es importante señalar que las directrices no están pensadas como una herramienta especializada para ninguno de estos grupos en particular: no profundizan en ningún campo de conocimiento concreto (técnico, jurídico o de políticas públicas). Por el contrario, están **diseñadas para grupos multidisciplinares que aborden conjuntamente un proyecto de IA**, manteniéndose deliberadamente en un nivel que permita un diálogo transversal entre disciplinas. Cada área de las directrices plantea preguntas diferentes, por lo que, según cuáles se formulen, distintos perfiles las encontrarán más relevantes. Pero la idea subyacente es que esto no debería ser un ejercicio aislado: diferentes actores pueden recorrerlo juntos, o de forma independiente, según el momento y el papel de cada uno en el proceso, con el objetivo de fomentar el intercambio de conocimientos y el diálogo entre ellos.

3. El marco de la Evaluación de Impacto Interseccional (EII)

Esta sección describe cómo utilizar estas directrices. La herramienta central que se presenta es la Matriz de la EII del anexo A, que permite un análisis estructurado de cómo las desigualdades sistémicas se trasladan a los sistemas de IA multimodales, desde el diseño hasta la implementación. Relaciona las diferentes fases del ciclo de vida de la IA con las formas de desigualdad que pueden surgir en cada una, y ofrece un conjunto de preguntas orientadoras con las que trabajar. A continuación se explica cómo aplicar la matriz paso a paso.

No es necesario utilizar toda la matriz a la vez. Empezad identificando en qué fase o fases del ciclo de vida os encontráis y qué dimensiones analíticas son más relevantes para la decisión que debéis tomar. Utilizad la EII como una herramienta para centrar la indagación, no para auditarlo todo exhaustivamente y de forma simultánea.

3.1. Calendario y uso de la EII

La EII no es un acontecimiento puntual. Debe llevarse a cabo tanto como **instrumento *ex ante*** (antes del despliegue, idealmente desde la fase de definición del problema) como **proceso continuo** que incorpore fases iterativas de re-evaluación y ajuste.

El momento de la EII es importante por dos razones. En primer lugar, **una evaluación más temprana permite la prevención en lugar de la reparación**: las decisiones de diseño, los protocolos de recogida de datos y las decisiones de infraestructura tomadas en las primeras fases son mucho más fáciles de ajustar desde una perspectiva interseccional que las correcciones a posteriori. En segundo lugar, **los sistemas de IA, especialmente los modelos fundacionales y multimodales, evolucionan**: se ajustan (*fine-tuning*), se actualizan, se integran en nuevos contextos y terceros acceden a ellos a través de APIs. Por lo tanto, la evaluación debe incorporarse a los ciclos de gobernanza y de actualización, y no debe tratarse como una entrega puntual.

3.2. Dimensiones analíticas

La EII se organiza en torno a tres dimensiones analíticas interconectadas. Estas dimensiones no son secuenciales: se refuerzan mutuamente y deben entenderse como componentes interdependientes de una evaluación unificada:

Vida-Máquina	Examina cómo los sistemas de IA afectan a la vida de diferentes comunidades, especialmente las marginalizadas. Se centra en la experiencia humana: quién se hace visible o invisible a través del sistema, cómo las decisiones afectan a la vida cotidiana, el trabajo de cuidados, el acceso y la dignidad, y cómo las personas afectadas pueden comprender y cuestionar el sistema.
Sistémica-Política	Examina dinámicas sociales, políticas y estructurales más amplias: cómo los desequilibrios de poder y las desigualdades sistémicas se reproducen o se cuestionan a través del diseño tecnológico, la contratación, la gobernanza y el despliegue. Aborda los contextos institucionales, el extractivismo de datos, la concentración de poder y la rendición de cuentas democrática.
Métodos-Métricas	Se centra en cómo se diseñan los procesos de evaluación: qué métricas de equidad se utilizan, si son interseccionales, cómo los métodos participativos informan el benchmark y si las herramientas de evaluación reflejan los valores que dicen defender. Incluye la atención a los protocolos de anotación, las declaraciones de los conjuntos de datos y los ciclos iterativos de retroalimentación.

Cada dimensión se operacionaliza mediante preguntas orientadoras, indicadores y criterios de evaluación en la Matriz de la EII (véase el anexo A). Las preguntas de la matriz están estructuradas para pasar de consideraciones a corto plazo y reflexivas a dimensiones a más largo plazo, estructurales y reparadoras.

3.3. Áreas del análisis

La EII se estructura en torno a **seis áreas que, en conjunto, cubren los ámbitos clave en los que pueden surgir daños interseccionales, exclusión y desigualdad estructural en los sistemas de IA.** No son pasos secuenciales que deban completarse por orden: una evaluación puede empezar por cualquier área, algunas serán más o menos relevantes según el sistema y el contexto, y todas deben considerarse susceptibles de ser reexaminadas a medida que el proyecto evoluciona. Lo que tienen en común las áreas es que **cada una concentra tipos específicos de riesgo interseccional**: configuraciones particulares de decisiones, relaciones de poder y condiciones estructurales que la EII debe interrogar.

En la Matriz de la EII (anexo A), estas áreas se organizan en relación con las tres dimensiones analíticas. La tabla siguiente presenta cada área y sus preguntas interseccionales centrales:

ÁREA	PREGUNTAS INTERSECCIONALES CLAVE
Definición del problema	¿Quién define el problema que el sistema de IA debe resolver? ¿Las necesidades, experiencias y conocimientos de quién se sitúan en el centro de esa definición, y los de quién están ausentes? ¿Es un enfoque basado en IA necesario y proporcionado, o corre el riesgo de codificar desigualdades estructurales desde el principio?
Datos y representación	¿Quién está representado en los datos de entrenamiento, de qué manera y en qué condiciones? ¿Las imágenes, el lenguaje y los contextos vividos de quién se utilizan, con qué consentimiento y con qué beneficio? ¿Qué falta, qué está distorsionado o estereotipado, y qué relaciones de poder están incrustadas en la recogida y la curación de datos?
Modelo y desarrollo	¿Qué decisiones técnicas (arquitectura, objetivos de optimización, métricas de equidad) codifican supuestos particulares sobre lo que se considera un resultado correcto o deseable? ¿Las métricas de equidad son interseccionales o evalúan ejes demográficos únicos? ¿Quién tiene el poder de decisión sobre estas opciones?
Equipos e instituciones	¿Quién construye, financia y gobierna el sistema? ¿Cómo se distribuyen la toma de decisiones, los roles técnicos y la visibilidad según el género, la raza y otras identidades que se entrecruzan dentro del equipo y de su contexto institucional? ¿Qué condiciones de contratación, laborales y ambientales sustentan la infraestructura?
Participación	¿Quién participa en el diseño, la evaluación y la gobernanza, y con qué grado de poder? ¿Las comunidades afectadas configuran realmente las decisiones o se las consulta sobre opciones ya tomadas? ¿Cómo se abordan las dinámicas de poder dentro de los procesos participativos?
Impacto	¿Quién se ve afectado por los resultados del sistema, directa e indirectamente? ¿Cómo difieren los impactos entre categorías sociales que se entrecruzan? ¿Qué mecanismos existen para identificar, notificar y reparar los daños, y llegan a las personas más afectadas?

3.4. La Matriz como herramienta operativa

La Matriz de la EII (anexo A) proporciona el banco detallado de preguntas para la evaluación. Se organiza como una cuadrícula: las **filas** corresponden a las tres **dimensiones analíticas** presentadas en la sección 3.2 (Vida-Máquina, Sistémica-Política, Métodos-Métricas), y las **columnas** corresponden a las seis **áreas** presentadas en la sección 3.3 (Definición del problema, Datos y representación, Modelo y desarrollo, Equipos e instituciones, Participación, Impacto). Cada fila de la matriz se subdivide, además, por subdimensiones, de modo que cada celda representa una **intersección subdimensión–área** concreta.

Cada celda contiene hasta **cuatro preguntas**, estructuradas de la siguiente manera:

→ **Una pregunta de apertura de sí/no:** una pregunta diagnóstica que hace aflorar rápidamente si existe un problema y que lleva a las personas evaluadoras a decidir si es necesario profundizar.

→ **Tres preguntas abiertas de seguimiento:** preguntas que invitan a la reflexión, la contextualización y el análisis sustantivo una vez respondida la pregunta de apertura.

Dentro de cada celda, las preguntas están **ordenadas a lo largo de un eje dimensional indicado en el encabezado de la fila.** Según la subdimensión, este eje puede ir del *corto plazo* al *largo plazo*, de la *reflexión* a la *revisión* de la *visión*, o de la *mitigación* a la *rendición de cuentas*, y avanza progresivamente de las cuestiones inmediatas y concretas hacia las acumulativas, estructurales y reparadoras.

La matriz no es una lista de verificación para completar de una sola vez, ni requiere una respuesta binaria de aprobado/suspenso. Es una **herramienta viva con la que trabajar en diferentes fases del proyecto y por parte de diferentes miembros del equipo.** No todas las celdas serán relevantes en todos los contextos, y algunas preguntas pueden justificar una respuesta de **«no aplicable»** debidamente motivada en lugar de una respuesta sustantiva. La pregunta de apertura de sí/no es un estímulo para la reflexión, no un mecanismo de puntuación.

Aunque la matriz no está concebida como una herramienta de puntuación, incluye una **pestaña opcional de puntuación tipo semáforo** para los equipos que deseen hacer un seguimiento cuantificado del progreso entre iteraciones. Los mismos umbrales se aplican a nivel de fase, de dimensión y global: verde ≥75% de respuestas afirmativas (S) (la perspectiva interseccional se ha integrado); amarillo 50–74% (la perspectiva interseccional se ha integrado parcialmente); y rojo por debajo del 50% (la perspectiva interseccional no se ha integrado). Las respuestas marcadas como NA (no aplicable) se excluyen del denominador, de modo que solo cuentan las preguntas consideradas relevantes en un contexto determinado. Estos umbrales sirven como guías de orientación indicativas más que como veredictos de aprobado/suspenso; el resultado sustantivo de la evaluación sigue siendo la reflexión cualitativa registrada junto a cada pregunta.

3.5. Del diagnóstico a la toma de decisiones

Una vez identificados los impactos potenciales a través de la matriz, la evaluación debe **traducir los resultados en decisiones estructuradas.** Para los sistemas de IA con una gran escalabilidad, incluidos los modelos fundacionales, la evaluación debe tener en cuenta no solo los impactos directos, sino también los usos posteriores, las actualizaciones del modelo, el acceso por API y los riesgos emergentes del despliegue en el mundo real.

Nos habría gustado ofrecer criterios más concretos y prescriptivos en esta fase. Sin embargo, dada la diversidad de sistemas, contextos e intereses en juego, cualquier umbral fijo correría el riesgo de ser demasiado rígido o demasiado limitado para tener sentido en todos los casos. Por lo tanto, lo que sigue pretende ser una orientación: cinco ámbitos de decisión que estructuran esta traducción, que deben trabajarse y ponderarse según los resultados específicos de la evaluación, más que una lista de verificación fija.

Cinco ámbitos de decisión estructuran esta traducción:

→ **Exposición diferencial y grupos afectados:** determinad qué personas o grupos soportan cargas desproporcionadas, incluidos los efectos indirectos o posteriores. Evaluad si las identidades que se entrecruzan intensifican la exposición en diferentes contextos de despliegue, y si determinadas comunidades quedan sistemáticamente excluidas, invisibilizadas o sobrecargadas a medida que el sistema escala.

→ **Efectos estructurales y sobre la desigualdad:** determinad si el sistema reproduce o amplifica las desigualdades estructurales, introduce nuevas asimetrías vinculadas a la extracción de datos o a la concentración tecnológica, redistribuye el poder de decisión de maneras que afectan de forma diferente a los grupos que se entrecruzan, o tiene un potencial transformador demostrable. Prestad especial atención a los efectos acumulativos y entre contextos propios de los modelos fundacionales.

→ **Gravedad, probabilidad, escalabilidad y riesgos emergentes:** evaluad la gravedad (alcance, magnitud, irreversibilidad, interdependencia de los derechos), la probabilidad contextual (incluidos los patrones previsibles de uso y uso indebido) y la probabilidad de que los impactos se repliquen o se amplifiquen a través del acceso por API, las actualizaciones, el ajuste (*fine-tuning*) o el despliegue por terceros. Los impactos graves, estructuralmente discriminatorios o no mitigables deben informar directamente la priorización y pueden activar criterios de continuar/detener (*go/no-go*).

→ **Adecuación de la prevención y la mitigación:** determinad si las medidas propuestas son proporcionadas a los niveles de riesgo identificados, si la mitigación aborda las causas estructurales y la exposición diferenciada, y si debe plantearse el rediseño, la limitación del alcance, el despliegue condicionado, la suspensión o el no despliegue.

→ **Reparación, rendición de cuentas y seguimiento continuo:** determinad si existen mecanismos de reparación accesibles y efectivos para los daños indirectos o posteriores, si las responsabilidades están claramente repartidas entre proveedores de modelos, responsables del despliegue e integradores, y si el seguimiento incorpora indicadores cuantitativos, evidencias cualitativas estructuradas y experiencia vivida. La re-evaluación periódica debe integrarse en los ciclos de actualización y en los procesos de gobernanza.

Glosario

Justicia algorítmica: orientación normativa y campo de estudio que vela por que los sistemas de IA produzcan resultados equitativos y no discriminatorios, y por que las personas afectadas por decisiones automatizadas tengan acceso a la explicación, la impugnación y la reparación.

Anotación: proceso de asignar etiquetas o categorías a los elementos de un conjunto de datos para entrenar sistemas de IA (p. ej., «persona», «violento», «NSFW»). Las prácticas de anotación codifican supuestos sociales y pueden introducir o amplificar sesgos.

Sesgo: tendencia sistemática de un sistema de IA, o de otros ámbitos, a producir resultados que favorecen o perjudican injustamente a determinados grupos o características. El sesgo puede originarse en los datos de entrenamiento, la arquitectura del modelo o las decisiones de despliegue, y a menudo refleja desigualdades sociales preexistentes.

Sistema de recuperación basado en CLIP: tipo de sistema de IA multimodal que utiliza el aprendizaje contrastivo para alinear representaciones de imagen y de texto en un espacio de incrustaciones (embeddings) compartido, lo que permite la búsqueda y la recuperación entre modalidades. El proyecto InterVisions analiza sistemas de este tipo.

Evaluación de impacto relativa a la protección de datos (EIPD): proceso exigido por el RGPD para identificar y mitigar los riesgos para la privacidad derivados de las actividades de tratamiento de datos. La EII se basa en la metodología de la EIPD y amplía su alcance a consideraciones interseccionales y de derechos fundamentales.

Conjunto de datos (dataset): colección estructurada de imágenes, textos, audio u otros datos utilizada para entrenar o evaluar sistemas de IA. La composición, la obtención y el etiquetado de los conjuntos de datos tienen implicaciones directas en la equidad de la representación.

Enfoque decolonial: perspectiva crítica que interroga cómo las estructuras de poder coloniales siguen condicionando la producción de conocimiento, la infraestructura tecnológica y las prácticas de extracción de datos, y que sitúa en el centro las epistemologías marginalizadas.

Justicia ambiental: dimensión analítica que examina las cargas ambientales desproporcionadas asociadas a la infraestructura de la IA (extracción de recursos, consumo energético, emisiones de carbono) y su distribución desigual entre comunidades y territorios.

Borrado / invisibilización: ausencia o infrarrepresentación de determinados cuerpos, culturas, identidades o experiencias en los conjuntos de datos y los sistemas de IA, que puede perpetuar exclusiones históricas.

Modelo fundacional: modelo de IA de grandes dimensiones entrenado a escala con datos amplios y adaptado a una gran variedad de tareas posteriores (p. ej., CLIP, variantes de GPT). Los modelos fundacionales no se clasifican necesariamente como de alto riesgo según el Reglamento de IA de la UE, pero pueden producir impactos sociales significativos que justifican una evaluación estructurada.

Evaluación de impacto relativa a los derechos fundamentales (FRIA): evaluación exigida por el artículo 27 del Reglamento de IA de la UE a los respon-

sables del despliegue de sistemas de IA de alto riesgo, con el objetivo de identificar los riesgos para los derechos fundamentales tal como los protege la Carta de los Derechos Fundamentales de la Unión Europea. La EII constituye una contribución a la FRIA.

Interseccionalidad: marco analítico, desarrollado por Kimberlé Crenshaw y ampliado, entre otras, por Patricia Hill Collins y Sirma Bilge, que examina cómo los ejes de opresión (género, raza, clase, discapacidad, sexualidad, edad, etc.) interactúan dentro de los sistemas de poder y producen formas diferenciadas y compuestas de discriminación y desigualdad.

Matriz de dominación: concepto desarrollado por Patricia Hill Collins para describir la organización del poder a lo largo de ejes de opresión que se entrecruzan y que operan simultáneamente en los niveles estructural, disciplinario, hegemónico e interpersonal.

Sistema de IA multimodal: sistema de IA que procesa y relaciona simultáneamente múltiples modalidades de datos, como texto, imágenes, audio y vídeo. Los sistemas multimodales plantean retos particulares para la evaluación de impacto interseccional debido a la propagación de sesgos entre modalidades.

Pregunta de apertura / pregunta de seguimiento: la matriz de la EII organiza cada área de evaluación en dos niveles: preguntas de apertura (sí/no/NA, que responden todos los equipos) que señalan posibles problemas, y preguntas de seguimiento que guían un análisis más profundo cuando se han identificado problemas.

Persona / personas (sujeto por defecto): en estas directrices, «personas» se refiere a todas las personas titulares de derechos, incluidas las que no están representadas en los datos, las que no son usuarias del sistema o las que resultan afectadas indirectamente por él. Desde una perspectiva feminista e interseccional, una «persona» genérica nunca es neutral: tanto los sistemas de IA como los marcos de evaluación tienden a tomar un sujeto dominante como referencia por defecto. Las personas evaluadoras deberían preguntarse a quién se presupone implícitamente cuando se habla de «personas», «usuarios» o «el público», y quién queda fuera.

Posicionalidad: contexto social y político que conforma la perspectiva de una persona o de un equipo, incluidas las dimensiones de género, raza, clase, disciplina y afiliación institucional. Reconocer la posicionalidad es un requisito previo para una práctica reflexiva de desarrollo de la IA.

Representación: quién aparece en los datos, cómo aparece y quién está ausente. Las decisiones de representación en los conjuntos de datos y en el diseño de la IA reflejan y reproducen jerarquías sociales.

Conocimiento situado: concepto desarrollado por Donna Haraway según el cual todo conocimiento se produce desde una posición social, cultural e histórica específica. No existe una «mirada desde ninguna parte» neutral; reconocer la posicionalidad es un requisito metodológico para la investigación feminista e interseccional.

Discriminación sistémica: discriminación producida y sostenida por estructuras, normas e instituciones más que por actos individuales aislados. La discriminación sistémica puede codificarse en los sistemas de IA a través de los datos de entrenamiento, los objetivos del modelo y los contextos de despliegue.

Violencia de género facilitada por la tecnología: violencia contra las mujeres y las niñas ejercida, amplificada o facilitada a través de tecnologías digitales, incluido el abuso sexual basado en imágenes, las imágenes íntimas no consentidas, el acoso persistente (stalking) y el acoso en línea. La aborda la Recomendación CM/Rec(2026)2 del Consejo de Europa sobre la rendición de cuentas por la violencia facilitada por la tecnología contra las mujeres y las niñas.

Referencias

Agarwal, S., et al. (2021). *Evaluating CLIP: Towards characterization of broader capabilities and downstream implications*. arXiv preprint.

Benjamin, R. (2019). *Race After Technology*. Polity.

Center for Data Science and Public Policy (DSaPP), University of Chicago. (2018). *Aequitas: The Bias and Fairness Audit Toolkit for Machine Learning.* Retrieved July 31, 2026, from https://dssg.github.io/aequitas/

Charter of Fundamental Rights of the European Union (2012/C 326/02). Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/treaty/char_2012/oj/eng

Crenshaw, Kimberle (1989). *Demarginalizing the Intersection of Race and Sex: A Black Feminist Critique of Antidiscrimination Doctrine, Feminist Theory and Antiracist Politics*. University of Chicago Legal Forum: Vol. 1989, Article 8. Available at: https://chicagounbound.uchicago.edu/uclf/vol1989/iss1/8

Collins, P. H., & Bilge, S. (2020). *Intersectionality* (2nd ed.). Polity Press.

Danish Institute for Human Rights. (2020). *Introduction to human rights impact assessment (HRIA Guidance and Toolbox)*. Retrieved July 31, 2026, from https://www.humanrights.dk/tools/human-rights-impact-assessment-guidance-toolbox/introduction-human-rights-impact-assessment

D'Ignazio, C., & Klein, L. (2019). *Data Feminism*. MIT Press.

European Commission, Directorate-General for Environment. (n.d.). *Environmental Impact Assessment (EIA)*. Retrieved July 31, 2026, from https://environment.ec.europa.eu/law-and-governance/environmental-assessments/environmental-impact-assessment-eia_en

European Commission, High-Level Expert Group on Artificial Intelligence. (2020). *Assessment List for Trustworthy Artificial Intelligence (ALTAI) for self-assessment*. Retrieved July 31, 2026, from https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment

European Parliament and Council of the European Union. (2016). *Regulation (EU) 2016/679 of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/reg/2016/679/oj/eng

European Parliament and Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng

Jääskeläinen, P., Sharma, N., Pallett, H. et al. (2025). *Intersectional analysis of visual generative AI: the case of stable diffusion*. AI & Soc 40, 4341–4362.

Hamidieh, K., Zhang, H., Gerych, W., Hartvigsen, T., & Ghassemi, M. (2024). *Identifying implicit social biases in vision-language models.* Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society.

Hausladen, C. I., Knott, M., Camerer, C. F., & Perona, P. (2025). *Social Perception of Faces in a Vision-Language Model*. Proceedings of the 2025 ACM Conference on Fairness, Accountability, and Transparency (FAccT '25).

Fairlearn. (n.d.). *Fairlearn: An open-source toolkit for assessing and improving fairness in AI*. Retrieved July 31, 2026, from https://fairlearn.org/

Leslie, D. (2019). *Understanding artificial intelligence ethics and safety: A guide for the responsible design and implementation of AI systems in the public sector*. The Alan Turing Institute. Retrieved July 31, 2026, from https://www.turing.ac.uk/news/publications/understanding-artificial-intelligence-ethics-and-safety

Observatori d'Ètica en Intel·ligència Artificial de Catalunya (OEIAC). (n.d.). *El Model PIO*. Retrieved July 31, 2026, from https://oeiac.cat/el-model/

Ovalle, A., Subramonian, A., Gautam, V., Gee, G., & Chang, K.-W. (2023). *Factoring the matrix of domination: A critical review and reimagination of intersectionality in AI fairness*. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society.

Ruiz García, S., & Gómez Bigordà, L. (2025). *Charting Pathways: An intersectional impact assessment for vision and language foundation models*. In M. Gutiérrez Almazor & A. M. Moreno Cano (Eds.), Women, Technology, and Power: Unmasking (and Dealing with) Digital Disparities in the Times of the Platforms (pp. 225–243). Tirant Humanidades.

Treasury Board of Canada Secretariat. (2021). *Directive on Automated Decision-Making*. Retrieved July 31, 2026, from https://www.tbs-sct.canada.ca/pol/doc-eng.aspx?id=32592

UNESCO. (n.d.). *Ethical Impact Assessment*. Retrieved July 31, 2026, from https://www.unesco.org/ethics-ai/en/eia

Anexo A: El marco de la EII

El anexo A, la Matriz de la EII, se distribuye como documento independiente. Proporciona el conjunto completo de preguntas orientadoras organizadas por dimensión analítica (filas: Vida-Máquina, Sistémica-Política y Métodos-Métricas) y por área del ciclo de vida (columnas). Se puede empezar a trabajar la matriz por cualquier área y utilizarla de forma no secuencial.

La matriz es un complemento operativo de estas directrices, no un documento autónomo. Debe utilizarse junto con la sección 3 de este documento, que explica cómo navegar por la matriz, interpretar sus resultados y traducir las conclusiones en decisiones concretas.

Acceded aquí:

https://nextcloud.alia.cat/index.php/s/eqq55YT3Zw9jxjT

Autoría y agradecimientos

Estas directrices se han elaborado en el marco del proyecto InterVisions. La autoría corresponde conjuntamente a las entidades socias del consorcio y al Grupo de Trabajo de las Directrices, que redactaron y desarrollaron juntos el contenido. Más abajo se agradece por separado al Consejo Asesor su revisión, sus aportaciones y su acompañamiento durante todo el proceso.

En consonancia con nuestro compromiso con la reflexividad crítica, las autoras y autores reconocen su propia posición dentro de las relaciones de poder examinadas en este informe, así como el modo en que sus trayectorias disciplinares y experiencias vividas han moldeado su diseño e interpretación, manteniéndose conscientes de estas dinámicas mediante una práctica reflexiva continua (Klumbytė, Draude, & Taylor, 2022; Civic, 2022).

Autoría

Consorcio

ALIA-Donestech:
Eva Cruells López, Mireia Orra i De Salsas

Computer Vision Center (CVC):
Lluís Gómez i Bigordà, Sofia Llàcer Caro

Diputació de Barcelona:
Sonia Ruiz García

Grupo de Trabajo de las Directrices

Maya Aidlin-Perlman
Marta Cruells López
Nadia Nadesan
Adrià Molina Rodríguez
Margarita Padilla García

Agradecimientos

Las autoras y autores agradecen sinceramente a los miembros del Consejo Asesor su revisión crítica y su acompañamiento en la elaboración de estas directrices, sin que asuman la responsabilidad de la autoría del texto:

Consejo Asesor

Yuki M. Asano
Sara Aguilar Ricart
Alex Cadon
Alba Elvira Guiral
Dimosthenis Karatzas
Laura Martín Montañez
Marisa Molina Alonso
Ana Paricio
PhD, Graziella Piga
H. Titilola Olojede
Dra. Núria Vergés Bosch

INTER VISIONS



Co-funded by
the European Union