Directrius per a l'Avaluació d'Impacte Interseccional

Un marc per avaluar els impactes interseccionals dels sistemes d'intel·ligència artificial, específicament en models de llenguatge i visió

INTER VISIONS

Co-funded by the European Union

Projecte: InterVisions (101214711)
CERV-2024-CHAR-LITI-CHARTER

Aquestes directrius han estat elaborades pel consorci InterVisions (ALIA-Donestech, Computer Vision Center i Diputació de Barcelona), amb les aportacions d'un Grup de Treball de les Directrius específic i d'un Consell Assessor. Els agraïments complets es troben a la pàgina 25.

INTER VISIONS



Co-funded by the European Union

Finançat per la Unió Europea. Les opinions i els punts de vista expressats només comprometen el seu autor o autors i no reflecteixen necessàriament els de la Unió Europea o els de l'Agència Executiva Europea d'Educació i Cultura (EACEA). Ni la Unió Europea ni l'EACEA en poden ser considerades responsables.

ÍNDEX

Introducció **4**
Context: models multimodals i fundacionals 4
La necessitat d'una Avaluació d'Impacte Interseccional 4
Finalitat i doble objectiu 5
Relació amb el Reglament d'IA de la UE i la FRIA 6

1. Posicionament i fonaments conceptuals **7**
1.1. Una revisió crítica dels marcs existents 7
1.2. La interseccionalitat com a marc analític 9
1.3. Focus específic: sistemes de recuperació basats en CLIP 10

2. Principis normatius i metodològics **11**
2.1. Principis substantius i procedimentals 11
2.2. Objectius de les directrius 14
2.3. Públic destinatari 14

3. El marc de l'Avaluació d'Impacte Interseccional (AII) **15**
3.1. Calendari i ús de l'AII 15
3.2. Dimensions analítiques 16
3.3. Àrees de l'anàlisi 17
3.4. La Matriu com a eina operativa 18
3.5. De la diagnosi a la presa de decisions 18

Glossari de termes clau **20**
Referències **22**
Annex A: El marc de l'AII **24**
Autoria i agraïments **25**

Com utilitzar aquest document: aquesta guia està pensada per ser modular. No cal recórrer totes les seccions de manera seqüencial. Segons el vostre rol i la fase de desenvolupament, feu servir l'índex per anar directament a la secció pertinent. El marc de l'AII (secció 3) és el nucli operatiu; la Matriu (annex A) ofereix el banc detallat de preguntes per a cada fase i dimensió analítica.

Introducció

Context: models multimodals i fundacionals

Els models fundacionals multimodals, sistemes d'intel·ligència artificial (IA) entrenats amb combinacions a gran escala de text, imatges i altres modalitats de dades, plantegen **reptes específics i poc examinats per a l'avaluació dels drets fonamentals.** La seva escala, la seva complexitat arquitectònica i la capacitat de ser desplegats en múltiples contextos posteriors fan que els danys sovint siguin difusos, acumulatius i difícils d'atribuir a una única decisió de disseny o a un únic punt de fallada.

Tal com documentem en el projecte InterVisions i una literatura acadèmica creixent, **els enfocaments existents d'auditoria de biaixos i d'avaluació de l'equitat tendeixen a ser tècnicament limitats.** Sovint avaluen categories demogràfiques aïllades en lloc de la seva intersecció, i rarament capten com les desigualtats estructurals es reprodueixen a través de la curació de dades, les decisions de disseny i les condicions de desplegament. Els models de visió i llenguatge com CLIP, que sustenten la recuperació d'imatges, l'ordenació de continguts i moltes aplicacions generatives, són especialment susceptibles a aquestes limitacions, ja que hereten biaixos de representació de dades web a gran escala i els distribueixen massivament a través dels sistemes que se'n deriven.

La necessitat d'una Avaluació d'Impacte Interseccional

Aquestes limitacions fan necessàries metodologies capaces d'integrar l'anàlisi tècnica amb el context social, el coneixement participatiu i les consideracions basades en drets. Una auditoria purament tècnica no pot fer aflorar

les maneres en què un sistema d'IA pot invisibilitzar determinades comunitats, assignar-les a categories estereotipades o exposar-les a danys desproporcionats. Una **Avaluació d'Impacte Interseccional** (AII o IIA per les seves sigles en anglès) està dissenyada per cobrir aquest buit.

L'AII ofereix una manera estructurada d'identificar qui pot resultar afectat per un sistema d'IA, com poden sorgir o intensificar-se els riscos i les desigualtats a través de categories socials que s'entrecreuen, i quines mesures poden ser necessàries per prevenir, mitigar o reparar els impactes adversos al llarg de tot el cicle de vida del sistema. No ho fa com un exercici puntual de compliment normatiu, sinó com un procés continu i participatiu d'escrutini i rendició de comptes.

Finalitat i doble objectiu

Aquestes directrius proporcionen una **metodologia pràctica** per dur a terme una IIA en el context dels sistemes d'IA, en particular dels **models multimodals i fundacionals**. Estan pensades per donar suport a les persones professionals en:

→ Identificar i analitzar de manera sistemàtica els impactes i les vulnerabilitats interseccionals al llarg de tot el cicle de vida del sistema d'IA.

→ Integrar perspectives tècniques, socials i participatives en un procés d'avaluació coherent.

→ Traduir els resultats en decisions concretes de prevenció, mitigació i reparació.

El marc té un **doble objectiu:**

→ **Aplicació interna:** oferir una guia pràctica per dur a terme l'anàlisi interseccional dins del projecte InterVisions, aplicable a les estructures de governança, pràctiques de dades, eines d'auditoria de biaixos, tallers participatius i benchmark tècnic.

→ **Replicabilitat:** oferir un enfocament metodològic adaptable a altres projectes amb sistemes d'IA multimodals o, de manera més àmplia, a qualsevol sistema d'IA el disseny i el desplegament del qual puguin produir impactes socials diferenciats.

En oferir un marc estructurat però adaptable, les directrius pretenen que les avaluacions d'impacte vagin més enllà del compliment purament procedimental i contribueixin, en canvi, a un desenvolupament i un desplegament de la IA més responsables, justos i alineats de manera fonamental amb els drets.

Important: aquestes directrius no prescriuen una única resposta correcta per a cada pregunta plantejada. No són una eina de puntuació. La seva finalitat és estimular la reflexió crítica, fer aflorar allò que no s'ha tingut en compte, donar suport a la presa de decisions substantives i promoure l'acció transformadora. Aquestes directrius no tenen per objectiu emetre un certificat de compliment.

Relació amb el Reglament d'IA de la UE i la FRIA

Aquesta Avaluació d'Impacte Interseccional constitueix una contribució a l'**avaluació d'impacte sobre els drets fonamentals (FRIA, per les seves sigles en anglès)** exigida per l'article 27 del Reglament d'IA de la UE. Si bé l'article 27 s'adreça formalment als responsables del desplegament de sistemes d'alt risc, el marc de l'AII s'aplica als sistemes d'IA de manera més àmplia, incloent-hi els models fundacionals i els sistemes multimodals, com ara els sistemes de recuperació basats en CLIP, que, tot i no estar necessàriament classificats d'alt risc, produeixen un impacte social significatiu i riscos interseccionals que requereixen una avaluació estructurada. Les organitzacions que duguin a terme una FRIA poden utilitzar la Matriu AII per fonamentar diversos dels elements que l'article 27 exigeix documentar als responsables del desplegament, com les categories de persones afectades, els riscos específics de dany, les mesures de supervisió humana i els mecanismes de reclamació; aquesta correspondència es podrà perfeccionar a mesura que es disposi d'orientació sobre la FRIA.

També es basa metodològicament en l'**avaluació d'impacte relativa a la protecció de dades (AIPD)** establerta pel Reglament General de Protecció de Dades (RGPD). Tanmateix, va més enllà d'aquests requisits: **adopta un enfocament interseccional i feminista que els marcs reguladors actuals encara no han integrat, i amplia l'abast de l'anàlisi a les desigualtats estructurals, la justícia ambiental i la governança participativa.**

Aquesta avaluació se situa, a més, dins del **marc de drets humans del Consell d'Europa per a la governança de la IA.** Es fonamenta en el Conveni marc sobre IA i drets humans, democràcia i estat de dret (STCE núm. 225, 2024), el primer tractat internacional vinculant sobre IA, que obliga els Estats part a garantir que els sistemes d'IA siguin compatibles amb els drets humans, la democràcia i l'estat de dret al llarg de tot el seu cicle de vida. També s'inspira en dues recomanacions del Consell d'Europa directament rellevants per a l'orientació feminista i interseccional d'aquesta avaluació: la Recomanació CM/Rec(2026)1 sobre igualtat i IA, que orienta els Estats a prevenir la discriminació per motius com el gènere, la raça i la SOGIESC (orientació sexual, identitat i expressió de gènere i característiques sexuals) al llarg de tot el cicle de vida de la IA; i la Recomanació CM/Rec(2026)2 sobre la rendició de comptes per la violència facilitada per la tecnologia contra les dones i les nenes, a la qual recorre aquesta avaluació quan examina com els sistemes d'IA poden facilitar, amplificar o no prevenir la violència de gènere facilitada per la tecnologia.

1. Posicionament i fonaments conceptuals

1.1. Una revisió crítica dels marcs existents

Diversos marcs consolidats aborden l'avaluació dels impactes dels sistemes d'IA. L'AII es basa en les seves aportacions alhora que n'aborda les limitacions rellevants per a l'anàlisi interseccional i feminista:

Marc	Principis clau	Principal limitació per a l'AII	Aplicabilitat
FRIA (Reglament d'IA de la UE, art. 27)	Avaluació obligatòria d'impacte sobre els drets fonamentals per a sistemes d'IA d'alt risc; abasta la dignitat, la no-discriminació, la privadesa i la tutela efectiva.	Procedimental i mínima: defineix l'abast però gairebé no ofereix orientació metodològica; sense marc interseccional	Tota la UE; obligatòria per als actors responsables del desplegament d'IA d'alt risc que siguin organismes de dret públic, entitats privades que prestin serveis públics o empreses que utilitzin IA per a la qualificació creditícia o la fixació de preus d'assegurances de vida o salut (arran de l'Òmnibus Digital sobre IA, l'aplicació s'ha ajornat fins al desembre de 2027).[1]
AIPD (en anglès, DPIA) del RGPD	Avaluació estructurada dels riscos de les dades; privadesa i protecció de dades des del disseny; obligatòria per a activitats de tractament d'alt risc.	Abast limitat: només protecció de dades; no aborda drets més amplis ni la representació.	UE/EEA (*European Economic Area*), amb abast extraterritorial; obligatòria per a qualsevol responsable del tractament, del sector públic o privat, amb tractaments que puguin comportar un alt risc per als drets de les persones.

1- Les normes per als sistemes d'IA d'alt risc integrats en productes regulats (annex I) disposen ara d'un període transitori ampliat fins al 2 d'agost de 2028, i les normes per als casos d'ús d'alt risc en àmbits sensibles (annex III, incloses la qualificació creditícia i la fixació de preus d'assegurances) s'amplien fins al 2 de desembre de 2027. Aquests canvis ja no són només un acord polític: van adquirir efectes jurídics com a Reglament (UE) 2026/1744 («Òmnibus Digital sobre IA»), que va entrar en vigor el 27 de juliol de 2026. Disponible a: https://digital-strategy.ec.europa.eu/en/library/digital-omnibus-ai-regulation-proposal

Marc	Principis clau	Principal limitació per a l'AII	Aplicabilitat
Canadà – Directiva sobre la presa de decisions automatitzada (DADM)	Directiva federal que exigeix una avaluació obligatòria d'impacte algorítmic (AIA) abans de desplegar sistemes governamentals de decisió automatitzada (ADS); els resultats de l'AIA determinen un de quatre nivells de risc, cadascun amb salvaguardes proporcionades.	Limitada als ADS federals i centrada en la paritat demogràfica sense anàlisi interseccional.	Només el govern federal canadenc; obligatòria per als ADS dels departaments que prenen decisions administratives que afecten la ciutadania o hi donen suport (excepte la seguretat nacional).
AI HLEG / ALTAI	Set requisits per a una IA fiable (supervisió, robustesa, privadesa, transparència, equitat, benestar, rendició de comptes); llista de verificació pràctica àmpliament utilitzada a la indústria europea.	Atenció moderada a la interseccionalitat; sense anàlisi estructural del poder; voluntària; enfocament d'equitat d'un sol eix.	UE; autoavaluació voluntària per a desenvolupadors i responsables del desplegament d'IA de tots els sectors, més utilitzada a la indústria.
Recomanació de la UNESCO sobre l'ètica de la IA + eina EIA	Un estàndard normatiu global amb quatre valors centrals (drets humans, inclusió, sostenibilitat, pluralisme); l'avaluació estructurada EIA abasta la delimitació de l'abast i una revisió basada en principis.	Més adequada per a la revisió ex ante de les contractacions que per a l'auditoria algorítmica continuada o les proves tècniques de biaixos, i no aborda el dany de representació específic de la IA multimodal.	Global; instrument normatiu no vinculant adreçat als governs i responsables polítics dels 194 Estats membres de la UNESCO; l'eina EIA la fan servir equips de projectes d'IA i comunitats afectades per avaluar els impactes dels sistemes.
Model PIO (Observatori d'Ètica en IA de Catalunya)	Un marc i una eina d'autoavaluació per mesurar l'alineament ètic dels sistemes d'IA que inclou set principis clau (transparència, equitat, seguretat, rendició de comptes, privadesa, autonomia, sostenibilitat).		Catalunya (regional); autoavaluació oberta i voluntària per a organitzacions del sector públic i privat, desenvolupada per l'OEIAC en el marc de l'estratègia d'IA de la Generalitat de Catalunya i harmonitzada amb el Reglament d'IA de la UE.
Alan Turing Institute - Guia d'ètica i seguretat de la IA	Guia d'ètica i seguretat de la IA orientada al sector públic que introdueix una «plataforma ètica» per dissenyar i desplegar la IA de manera responsable. Posa èmfasi en la governança basada en processos (ètica del flux de treball, rols, documentació).	Dissenyada principalment per a contextos del sector públic del Regne Unit i no aborda adequadament la interseccionalitat ni els danys de representació.	Sector públic del Regne Unit; orientació voluntària per a departaments governamentals i personal funcionari que dissenya i desplega IA.

Marc	Principis clau	Principal limitació per a l'AII	Aplicabilitat
HRIA (Human Rights Impact Assessment - Avaluació d'Impacte en Drets Humans)	Implicació sòlida de les persones titulars de drets; lògica de diligència deguda; identificació dels grups afectats; mecanismes de reparació i de queixa.	Operacionalització limitada per a sistemes tècnics d'IA; rarament adaptada a contextos algorítmics o multimodals.	Intersectorial i global; utilitzada per empreses i institucions, fonamentada en els Principis rectors de les Nacions Unides sobre les empreses i els drets humans; voluntària / basada en la diligència deguda.
Eines d'equitat - *fairness* (e.g. Aequitas, Fairlearn)	Operacionalitzen mètriques quantitatives d'equitat; detecció automatitzada de disparitats de rendiment entre grups demogràfics.	Anàlisi demogràfica d'un sol eix; sense component participatiu; l'enfocament tècnic es desconnecta dels drets i del context estructural.	Independents del sector; biblioteques tècniques de codi obert per a personal desenvolupador d'aprenentatge automàtic i científics de dades; voluntàries.
EIA (Environmental Impact Assessment - Avaluació d'Impacte Ambiental)	Anàlisi estructurada dels danys al llarg del cicle de vida; identificació de mesures de mitigació; principis de precaució i proporcionalitat.	No aborda les categories socials, els drets, la interseccionalitat ni el dany de representació.	Prevista per llei en moltes jurisdiccions; obligatòria per a promotors de projectes i autoritats públiques que aproven grans projectes (àmbit ambiental, no relacionat amb la IA, inclosa com a anàleg metodològic).

1.2. La interseccionalitat com a marc analític

La interseccionalitat, teoritzada originalment per Kimberlé Crenshaw (1989) per comprendre els efectes combinats de la raça i el gènere en contextos jurídics, constitueix l'eix analític d'aquesta avaluació. En el context dels sistemes d'IA, l**a interseccionalitat implica reconèixer que l'exposició al dany, la invisibilitat i l'exclusió no es distribueixen de manera uniforme dins de cap categoria social única.** Ben al contrari, les persones experimenten els sistemes d'IA a través de la interacció simultània del gènere, la raça, l'ètnia, la classe, la discapacitat, la neurodiversitat, l'edat, la sexualitat, la situació migratòria i altres dimensions de la posició social.

El marc de Crenshaw identifica identitats superposades i posa de relleu les maneres en què els sistemes de poder i els dispositius institucionals que s'entrecreuen produeixen formes particulars de desavantatge i exclusió. A partir d'aquesta idea, Patricia Hill Collins i Sirma Bilge (2016), basant-se en el concepte anterior de Collins de «matriu de dominació», desenvolupen la **interseccionalitat com una anàlisi estructural** de com el racisme, el capitalisme, l'heteropatriarcat, el colonialisme i el capacitisme, entre d'altres, s'organitzen a través de les institucions socials i es reprodueixen a través de les pràctiques quotidianes, incloses les tecnològiques. Des d'aquesta perspectiva, no importa només qui pateix el dany, sinó quins dispositius estructurals el fan possible, previsible i sovint invisible.

Aquesta distinció té conseqüències per a l'AII: significa que l'avaluació no es pot limitar a identificar quins grups demogràfics estan infrarepresentats o mal classificats. Ha de preguntar quins sistemes de poder, incrustats en les pràctiques de recollida de dades, les decisions de contractació, les cultures organitzatives i les lògiques de mercat, es reprodueixen a través del disseny i el desplegament del sistema d'IA. Charting

Pathways (2024), que també es basa en D'Ignazio i Klein (2019), Benjamin (2019) i Ovalle et al. (2023) -vegeu les referències-, operacionalitza aquest enfocament estructural traçant els canals pels quals les desigualtats sistèmiques es traslladen als sistemes d'IA: des de les condicions del treball de dades fins a la concentració del poder de decisió en el desenvolupament tecnològic.

Aquest marc opera en tres nivells:

→ **Micro (individual):** Com representa, o representa malament, el sistema les persones individuals a través de categories que s'entrecreuen? L'experiència de qui es fa visible, i la de qui s'esborra o s'estereotipa?

→ **Meso (institutional)**: Quines dinàmiques organitzatives, comercials i polítiques condicionen com es construeix i es desplega el sistema? Com reprodueixen o qüestionen les cultures institucionals les desigualtats estructurals?

→ **Macro (poder estructural)**: Com es relaciona el sistema amb els sistemes de poder més amplis -capitalisme, colonialisme, heteropatriarcat, capacitisme? Els reprodueix o els qüestiona?

A la pràctica, això significa que per a l'AII no n'hi ha prou amb mètriques de diversitat demogràfica. Tal com va assenyalar el grup de treball d'InterVisions, **la representació demogràfica no garanteix la consciència política de les relacions de poder**. L'avaluació ha d'examinar si **els patrons interseccionals de desavantatge s'identifiquen, s'aborden i es qüestionen activament,** i no només si es reconeixen.

1.3. Focus específic: sistemes de recuperació basats en CLIP

Dins del projecte InterVisions, l'AII s'aplica específicament als models de visió i llenguatge basats en CLIP utilitzats en tasques de recuperació d'imatges.

Aquests sistemes tenen una rellevància interseccional particular perquè:

→ S'entrenen amb **dades web a gran escala** que codifiquen biaixos socials existents tant en el llenguatge com en les imatges (Hamidieh et al., 2024).

→ Funcionen com a **components d'ús general** que hereten les aplicacions posteriors, de manera que les decisions de representació es propaguen àmpliament.

→ Les tasques de recuperació determinen directament **què es fa visible, rellevant o localitzable**, amb efectes concrets en l'accés a la informació i la representació cultural.

→ La recerca prèvia mostra que **conceptes genèrics** com «persona» tendeixen a associar-se amb subjectes blancs, de mitjana edat, sense discapacitat i d'aparença masculina, mentre que altres grups estan infrarepresentats o vinculats a contextos estereotipats o marginalitzats (Agarwal et al., 2021 i Hausladen et al., 2025).

→ **Mesurar el biaix en aquests sistemes és en si mateix problemàtic:** requereix etiquetar les persones segons categories demogràfiques percebudes (p. ex. gènere, raça, edat, discapacitat), la qual cosa comporta el risc de caure en categoritzacions essencialistes (D'Ignazio & Klein, 2020) i en l'assignació errònia de gènere o categoria (*misgendering* o *miscategorisation*) (Scheuerman et al., 2019); a més, com més fines són les interseccionalitats considerades, més petites són les mostres, cosa que limita la fiabilitat de les mètriques quantitatives.

La manca de consens a la literatura sobre equitat pel que fa a com mesurar o resoldre aquests biaixos fa encara més essencial la dimensió participativa i interseccional d'aquest marc.

2. Principis normatius i metodològics

A partir del **context regulador** descrit a la introducció (cf. article 27 del Reglament d'IA de la UE; RGPD), aquesta secció exposa els drets fonamentals i els principis normatius que guien l'AII en els sistemes d'IA, inclosos els models multimodals i fundacionals més enllà de la categoria d'alt risc. La seva finalitat és identificar i avaluar els possibles impactes sobre els drets fonamentals, determinar quines persones i grups poden resultar afectats (incloses les que es troben en situació de vulnerabilitat) i definir les mesures adequades per prevenir o mitigar els impactes adversos.

Per tant, l'avaluació hauria de considerar, com a mínim, els drets fonamentals següents, tal com els protegeix la **Carta dels Drets Fonamentals de la Unió Europea**: dignitat i integritat personal (articles 1 i 3); privadesa i protecció de dades (articles 7 i 8); llibertats i participació en la societat (articles 11, 12 i 16); igualtat i no-discriminació (articles 20, 21 i 23); protecció dels grups vulnerables (articles 24, 25 i 26); i garanties procedimentals i tutela efectiva (articles 41, 47 i 48).

Per garantir la protecció efectiva dels drets fonamentals esmentats en el context de sistemes d'IA que poden produir impactes socials diferenciats, l'Avaluació d'Impacte Interseccional es guia pels **principis substantius i procedimentals que es descriuen a continuació.** Dos d'aquests principis (la perspectiva feminista i interseccional, i la cura) són transversals: han d'informar no només el principi que els és propi, sinó també com es dissenyen, al llarg de tota l'avaluació, la definició del problema, les pràctiques de dades, la participació, la metodologia, les proves i la mitigació.

2.1. Principis substantius i procedimentals

L'AII es regeix per onze principis. No són compromisos abstractes: cadascun s'ha d'operacionalitzar mitjançant decisions concretes sobre com es dissenya i es duu a terme l'avaluació.

1.
Referents normatius i tècnics

L'avaluació s'ha de fonamentar en el dret internacional i europeu dels drets humans com a marc normatiu principal. També ha de tenir en compte referents tècnics i reguladors, com ara els estàndards de gestió de riscos de la IA, els requisits de governança de dades i les mètriques d'equitat reconegudes, de manera que el compliment tècnic doni suport a la protecció dels drets fonamentals, i no la substitueixi.

2.
Perspectiva feminista i interseccional

L'avaluació adopta un enfocament feminista i interseccional que examina com les infraestructures digitals, les pràctiques de dades i la presa de decisions automatitzada poden reproduir, amplificar o no prevenir les desigualtats estructurals, la discriminació i la violència. El gènere, la raça, la classe, la discapacitat, la neurodiversitat, l'edat, la sexualitat, la situació migratòria i altres factors que s'entrecreuen condicionen tant l'exposició al dany com l'accés a la protecció i a la reparació. Exigeix parar atenció a la violència de gènere facilitada per la tecnologia i als sistemes d'IA que difuminen la frontera entre allò públic i allò privat, amb una sensibilitat especial envers el contingut íntim (cf. Recomanació CM/Rec(2026)2 del Consell d'Europa).

3.
Cures

Les cures són un principi transversal, no limitat a una sola fase. Exigeix atenció al treball de cures no remunerat i a la reproducció social, sovint invisibles en les avaluacions tècniques, així com al benestar de les persones participants i provadores (testers), que han de comptar amb salvaguardes emocionals i psicològiques quan treballen amb contingut violent o sexualitzat. La cura s'ha d'integrar al llarg de tot el procés de l'AII i no s'ha de tractar com una cosa opcional.

4.
Participació

S'ha de garantir la participació significativa de les persones titulars de drets, incloses les afectades directament i indirectament, en totes les fases de l'avaluació. La participació ha de ser accessible, sensible al context i iniciada aviat, de manera que permeti una implicació sostinguda en les qüestions relatives a l'ús de les dades, el disseny del sistema i els possibles impactes. La diversitat demogràfica per si sola no constitueix una participació significativa; cal parar atenció a les dinàmiques de poder dins dels grups participants i entre ells.

5.
Empoderament

El procés ha d'enfortir la capacitat de les persones i les comunitats per comprendre i qüestionar els sistemes automatitzats que les afecten. Això inclou facilitar l'accés a explicacions clares, el suport en alfabetització digital i l'exercici efectiu dels drets de protecció de dades i altres drets digitals.

6.
Transparència i governança de dades

L'avaluació ha de garantir la transparència no només del seu propi procés, sinó també del funcionament del sistema d'IA, de les seves fonts de dades i de les seves estructures de governança, tot preservant la privadesa. S'ha de proporcionar informació clara i accessible sobre la recollida de dades, la lògica del tractament, la gestió de riscos i els mecanismes de supervisió.

7.
Rendició de comptes

S'han d'assignar responsabilitats clares per identificar, prevenir i abordar els impactes adversos, amb el suport de recursos i coneixements adequats. La metodologia d'avaluació mateixa ha de restar sotmesa a escrutini i a revisió periòdica, i ha de funcionar com un mecanisme substantiu de protecció de drets, no com un exercici de compliment formalista o de mer tràmit.

8.
Abast i gravetat dels impactes

L'avaluació ha d'identificar els impactes reals i potencials causats pel sistema d'IA o vinculats a aquest, inclosos els efectes acumulatius i heretats. Els impactes s'han d'avaluar segons la seva gravetat: abast (quantes persones es veuen afectades), magnitud (amb quina gravetat), irreversibilitat (si el dany és reparable), vulnerabilitat dels grups afectats i interdependència dels drets.

9.
Mitigació i accés a la reparació

S'han d'abordar tots els impactes adversos identificats, prioritzant els més greus. Les mesures han de seguir una jerarquia de prevenció, mitigació i reparació. S'han de garantir mecanismes de queixa accessibles i formes adequades de reparació, inclosa la reparació material i simbòlica.

10.
Sostenibilitat ambiental

L'avaluació ha d'examinar les implicacions ambientals del sistema d'IA al llarg de tot el seu cicle de vida: consum energètic, infraestructura de maquinari, emissions de carboni i extracció de materials. Els danys ambientals s'han d'analitzar en relació amb les seves conseqüències per als drets humans, especialment per a les comunitats afectades de manera desproporcionada per la injustícia ambiental.

11.
Poder estructural, extractivisme i governança democràtica

L'avaluació ha de valorar si el sistema d'IA reforça la concentració econòmica, l'extractivisme de dades o les asimetries estructurals de poder tecnològic. Cal parar atenció a la salvaguarda dels valors democràtics, a la prevenció d'una concentració indeguda d'influència i a garantir que el desplegament de la IA no soscavi el pluralisme, la justícia social ni l'autodeterminació col·lectiva.

2.2. Objectius de les directrius

Aquestes directrius tenen per objectiu:

→ Garantir **l'equitat**, **la inclusió** i **la rendició de comptes** en el disseny, el desenvolupament i el desplegament dels sistemes d'IA.

→ Protegir la **privadesa i les dades personals** com a drets fonamentals al llarg de tot el cicle de vida de la IA.

→ Promoure la **justícia ambiental** avaluant la petjada de recursos i emissions de la IA en relació amb els drets humans.

→ Fomentar **l'autoreflexivitat** entre les persones professionals, encoratjant un examen continu de la posicionalitat i de les dinàmiques de poder dins dels equips de projecte.

→ Facilitar la transferència de **coneixement interseccional** entre disciplines i contextos de projecte.

2.3. Públic destinatari

Aquestes directrius s'adrecen a qualsevol persona implicada en auditories algorítmiques interseccionals, disseny participatiu d'IA o governança responsable de la IA, especialment quan hi intervenen sistemes multimodals. Això inclou, entre d'altres: **entitats finançadores i titulars de projectes** que estableixen les condicions del desenvolupament de la IA; **desenvolupadors d'IA, personal investigador i equips tècnics** que construeixen o avaluen sistemes; **persones facilitadores de tallers i investigadores comunitàries** que condueixen processos participatius; i **institucions públiques, organismes reguladors i organitzacions de la societat civil** implicades en la supervisió o la contractació de la IA.

Cal destacar que les directrius no estan pensades com una eina especialitzada per a cap d'aquests grups en concret: no aprofundeixen en cap camp de coneixement determinat (tècnic, jurídic o de polítiques públiques). Al contrari, estan **dissenyades per a grups multidisciplinaris que abordin conjuntament un projecte d'IA**, mantenint-se deliberadament en un nivell que permeti un diàleg transversal entre disciplines. Cada àrea de les directrius planteja preguntes diferents, per la qual cosa, segons quines es formulin, diferents perfils les trobaran més rellevants. Però la idea de fons és que això no hauria de ser un exercici aïllat: diferents actors poden recórrer-lo junts, o de manera independent, segons el moment i el paper de cadascú en el procés, amb l'objectiu de fomentar l'intercanvi de coneixements i el diàleg entre ells.

3. El marc de l'Avaluació d'Impacte Interseccional (AII)

Aquesta secció descriu **com utilitzar aquestes directrius**. L'eina central que s'hi presenta és la Matriu de l'AII de l'annex A, que permet una anàlisi estructurada de com les desigualtats sistèmiques es traslladen als sistemes d'IA multimodals, des del disseny fins a la implementació. Relaciona les diferents fases del cicle de vida de la IA amb les formes de desigualtat que poden sorgir en cadascuna, i ofereix un conjunt de preguntes orientadores per treballar-hi. A continuació s'explica com aplicar la matriu pas a pas.

No cal utilitzar tota la matriu alhora. Comenceu identificant en quina fase o fases del cicle de vida us trobeu i quines dimensions analítiques són més rellevants per a la decisió que heu de prendre. Utilitzeu l'AII com una eina per centrar l'avaluació, no per auditar-ho tot exhaustivament i de manera simultània.

3.1. Calendari i ús de l'IIA

L'AII no és un esdeveniment puntual. S'ha de dur a terme tant com a **instrument *ex ante*** (abans del desplegament, idealment des de la fase de definició del problema) com a **procés continu** que incorpori fases iteratives de reavaluació i ajustament.

El moment de l'AII és important per dues raons. En primer lloc, **una avaluació més primerenca permet la prevenció en lloc de la reparació**: les decisions de disseny, els protocols de recollida de dades i les decisions d'infraestructura preses en les primeres fases són molt més fàcils d'ajustar des d'una perspectiva interseccional que les correccions a posteriori. En segon lloc, **els sistemes d'IA, especialment els models fundacionals i multimodals, evolucionen**: s'ajusten (*fine-tuning*), s'actualitzen, s'integren en nous contextos i terceres parts hi accedeixen a través d'APIs. Per tant, l'avaluació s'ha d'incorporar als cicles de governança i d'actualització, i no s'ha de tractar com un lliurament puntual.

3.2. Dimensions analítiques

L'AII s'organitza al voltant de tres dimensions analítiques interconnectades. Aquestes dimensions no són seqüencials: es reforcen mútuament i s'han d'entendre com a components interdependents d'una avaluació unificada:

Vida-Màquina	Examina com els sistemes d'IA afecten la vida de diferents comunitats, especialment les marginalitzades. Se centra en l'experiència humana: qui es fa visible o invisible a través del sistema, com les decisions afecten la vida quotidiana, el treball de cures, l'accés i la dignitat, i com les persones afectades poden comprendre i qüestionar el sistema.
Sistèmica-Política	Examina dinàmiques socials, polítiques i estructurals més àmplies: com els desequilibris de poder i les desigualtats sistèmiques es reprodueixen o es qüestionen a través del disseny tecnològic, la contractació, la governança i el desplegament. Aborda els contextos institucionals, l'extractivisme de dades, la concentració de poder i la rendició de comptes democràtica.
Mètodes-Mètriques	Se centra en com es dissenyen els processos d'avaluació: quines mètriques d'equitat s'utilitzen, si són interseccionals, com els mètodes participatius informen el benchmark i si les eines d'avaluació reflecteixen els valors que diuen defensar. Inclou l'atenció als protocols d'anotació, les declaracions dels conjunts de dades i els cicles iteratius de retroalimentació.

Cada dimensió s'operacionalitza mitjançant preguntes orientadores, indicadors i criteris d'avaluació a la Matriu de l'AII (vegeu l'annex A). Les preguntes de la matriu estan estructurades per passar de reflexions i consideracions a curt termini a dimensions estructurals i reparadores a més llarg termini.

3.3. Àrees de l'anàlisi

L'AII s'estructura al voltant de **sis àrees que, conjuntament, cobreixen els àmbits clau en què poden sorgir danys interseccionals, exclusió i desigualtat estructural en els sistemes d'IA.** No són passos seqüencials que s'hagin de completar per ordre: una avaluació pot començar per qualsevol àrea, algunes seran més o menys rellevants segons el sistema i el context, i totes s'han de considerar susceptibles de ser reexaminades a mesura que el projecte evoluciona. El que tenen en comú les àrees és que cadascuna concentra tipus específics de risc interseccional: configuracions particulars de decisions, relacions de poder i condicions estructurals que l'AII ha d'interrogar.

A la Matriu de l'IIA (annex A), aquestes àrees s'organitzen en relació amb les tres dimensions analítiques. La taula següent presenta cada àrea i les seves preguntes interseccionals centrals:

ÀREA	PREGUNTES INTERSECCIONALS CLAU
Definició del problema	Qui defineix el problema que el sistema d'IA ha de resoldre? Les necessitats, experiències i coneixements de qui se situen al centre d'aquesta definició, i els de qui hi són absents? Un enfocament basat en IA és necessari i proporcionat, o corre el risc de codificar desigualtats estructurals des del principi?
Dades i representació	Qui està representat a les dades d'entrenament, de quina manera i en quines condicions? Les imatges, el llenguatge i els contextos viscuts de qui s'utilitzen, amb quin consentiment i amb quin benefici? Què hi falta, què està distorsionat o estereotipat, i quines relacions de poder hi ha incrustades en la recollida i la curació de dades?
Model i desenvolupament	Quines decisions tècniques (arquitectura, objectius d'optimització, mètriques d'equitat) codifiquen supòsits particulars sobre què es considera un resultat correcte o desitjable? Les mètriques d'equitat són interseccionals o avaluen eixos demogràfics únics? Qui té el poder de decisió sobre aquestes opcions?
Equips i institucions	Qui construeix, finança i governa el sistema? Com es distribueixen la presa de decisions, els rols tècnics i la visibilitat segons el gènere, la raça i altres identitats que s'entrecreuen dins de l'equip i del seu context institucional? Quines condicions de contractació, laborals i ambientals sustenten la infraestructura?
Participació	Qui participa en el disseny, l'avaluació i la governança, i amb quin grau de poder? Les comunitats afectades configuren realment les decisions o se les consulta sobre opcions ja preses? Com s'aborden les dinàmiques de poder dins dels processos participatius?
Impacte	Qui es veu afectat pels resultats del sistema, directament i indirectament? Com difereixen els impactes entre categories socials que s'entrecreuen? Quins mecanismes hi ha per identificar, notificar i reparar els danys, i arriben a les persones més afectades?

3.4. La Matriu com a eina operativa

La Matriu de l'AII (annex A) proporciona el banc detallat de preguntes per a l'avaluació. S'organitza com una graella: les **files** corresponen a les tres **dimensions analítiques** presentades a la secció 3.2 (Vida-Màquina, Sistèmica-Política, Mètodes-Mètriques), i les columnes corresponen a les sis **àrees** presentades a la secció 3.3 (Definició del problema, Dades i representació, Model i desenvolupament, Equips i institucions, Participació, Impacte). Cada fila de la matriu se subdivideix, a més, per subdimensions, de manera que cada cel·la representa una **intersecció subdimensió–àrea** concreta.

Cada cel·la conté fins a **quatre preguntes**, estructurades de la manera següent:

→ **Una pregunta d'obertura de sí/no:** una pregunta diagnòstica que fa aflorar ràpidament si hi ha un problema i que porta les persones avaluadores a decidir si cal aprofundir-hi.

→ **Tres preguntes obertes de seguiment:** preguntes que conviden a la reflexió, la contextualització i l'anàlisi substantiva un cop s'ha respost la pregunta d'obertura.

Dins de cada cel·la, les preguntes estan **ordenades al llarg d'un eix dimensional indicat a la capçalera de la fila.** Segons la subdimensió, aquest eix pot anar del *curt termini al llarg termini*, de la *reflexió* a la *revisió* de la *visió*, o de la mitigació a la rendició de comptes, i avança progressivament de les qüestions immediates i concretes cap a les acumulatives, estructurals i reparadores.

La matriu no és una llista de verificació per completar d'una sola vegada, ni requereix una resposta binària d'aprovat/suspès. És una eina viva amb la qual s'ha de treballar en diferents fases del projecte i per part de diferents membres de l'equip. No totes les cel·les seran rellevants en tots els contextos, i algunes preguntes poden justificar una resposta de **«no aplicable»** degudament motivada en lloc d'una resposta substantiva. La pregunta d'obertura de sí/no és un estímul per a la reflexió, no un mecanisme de puntuació.

Tot i que la matriu no està concebuda com una eina de puntuació, inclou una **pestanya opcional de puntuació tipus semàfor** per als equips que vulguin fer un seguiment quantificat del progrés entre iteracions. Els mateixos llindars s'apliquen a nivell de fase, de dimensió i global: verd ≥75% de respostes afirmatives (S) (la perspectiva interseccional s'ha integrat); groc 50–74% (la perspectiva interseccional s'ha integrat parcialment); i vermell per sota del 50% (la perspectiva interseccional no s'ha integrat). Les respostes marcades com a NA (no aplicable) s'exclouen del denominador, de manera que només compten les preguntes considerades rellevants en un context determinat. Aquests llindars serveixen com a guies d'orientació indicatives més que no pas com a veredictes d'aprovat/suspès; el resultat substantiu de l'avaluació continua sent la reflexió qualitativa registrada al costat de cada pregunta.

3.5. De la diagnosi a la presa de decisions

Un cop identificats els impactes potencials a través de la matriu, l'avaluació ha de **traduir els resultats en decisions estructurades.** Per als sistemes d'IA amb una gran escalabilitat, inclosos els models fundacionals, l'avaluació ha de tenir en compte no només els impactes directes, sinó també els usos posteriors, les actualitzacions del model, l'accés per API i els riscos emergents del desplegament en el món real.

Ens hauria agradat oferir criteris més concrets i prescriptius en aquesta fase. Tanmateix, atesa la diversitat de sistemes, contextos i interessos en joc, qualsevol llindar fix correria el risc de ser massa rígid

o massa limitat per tenir sentit en tots els casos. Per tant, el que segueix pretén ser una orientació: cinc àmbits de decisió que estructuren aquesta traducció, que s'han de treballar i ponderar segons els resultats específics de l'avaluació, més que no pas una llista de verificació fixa.

Cinc àmbits de decisió estructuren aquesta traducció:

→ **Exposició diferencial i grups afectats:** determineu quines persones o grups suporten càrregues desproporcionades, inclosos els efectes indirectes o posteriors. Avalueu si les identitats que s'entrecreuen intensifiquen l'exposició en diferents contextos de desplegament, i si determinades comunitats queden sistemàticament excloses, invisibilitzades o sobrecarregades a mesura que el sistema escala.

→ **Efectes estructurals i sobre la desigualtat:** determineu si el sistema reprodueix o amplifica les desigualtats estructurals, introdueix noves asimetries vinculades a l'extracció de dades o a la concentració tecnològica, redistribueix el poder de decisió de maneres que afecten de manera diferent els grups que s'entrecreuen, o té un potencial transformador demostrable. Pareu una atenció especial als efectes acumulatius i entre contextos propis dels models fundacionals**.**

→ **Gravetat, probabilitat, escalabilitat i riscos emergents:** avalueu la gravetat (abast, magnitud, irreversibilitat, interdependència dels drets), la probabilitat contextual (incloent-hi els patrons previsibles d'ús i d'ús indegut) i la probabilitat que els impactes es repliquin o s'amplifiquin a través de l'accés per API, les actualitzacions, l'ajustament (*fine-tuning*) o el desplegament per terceres parts. Els impactes greus, estructuralment discriminatoris o no mitigables han d'informar directament la priorització i poden activar criteris de continuar/aturar (*go/no-go*).

→ **Adequació de la prevenció i la mitigació:** determineu si les mesures proposades són proporcionades als nivells de risc identificats, si la mitigació aborda les causes estructurals i l'exposició diferenciada, i si cal plantejar-se el redisseny, la limitació de l'abast, el desplegament condicionat, la suspensió o el no-desplegament.

→ **Reparació, rendició de comptes i seguiment continu:** determineu si existeixen mecanismes de reparació accessibles i efectius per als danys indirectes o posteriors, si les responsabilitats estan clarament repartides entre proveïdors de models, responsables del desplegament i integradors, i si el seguiment incorpora indicadors quantitatius, evidències qualitatives estructurades i experiència viscuda. La reavaluació periòdica s'ha d'integrar en els cicles d'actualització i en els processos de governança.

Glossari

Justícia algorítmica: orientació normativa i camp d'estudi que vetlla perquè els sistemes d'IA produeixin resultats equitatius i no discriminatoris, i perquè les persones afectades per decisions automatitzades tinguin accés a l'explicació, la impugnació i la reparació.

Anotació: procés d'assignar etiquetes o categories als elements d'un conjunt de dades per entrenar sistemes d'IA (p. ex., «persona», «violent», «NSFW»). Les pràctiques d'anotació codifiquen supòsits socials i poden introduir o amplificar biaixos.

Biaix: tendència sistemàtica d'un sistema d'IA, o d'altres àmbits, a produir resultats que afavoreixen o perjudiquen injustament determinats grups o característiques. El biaix pot originar-se en les dades d'entrenament, l'arquitectura del model o les decisions de desplegament, i sovint reflecteix desigualtats socials preexistents.

Sistema de recuperació basat en CLIP: tipus de sistema d'IA multimodal que utilitza l'aprenentatge contrastiu per alinear representacions d'imatge i de text en un espai d'incrustacions (*embeddings*) compartit, cosa que permet la cerca i la recuperació entre modalitats. El projecte InterVisions analitza sistemes d'aquest tipus.

Avaluació d'impacte relativa a la protecció de dades (AIPD): procés exigit pel RGPD per identificar i mitigar els riscos per a la privadesa derivats de les activitats de tractament de dades. L'AII es basa en la metodologia de l'AIPD i n'amplia l'abast a consideracions interseccionals i de drets fonamentals.

Conjunt de dades (*dataset*): col·lecció estructurada d'imatges, textos, àudio o altres dades utilitzada per entrenar o avaluar sistemes d'IA. La composició, l'obtenció i l'etiquetatge dels conjunts de dades tenen implicacions directes en l'equitat de la representació.

Enfocament decolonial: perspectiva crítica que interroga com les estructures de poder colonials continuen condicionant la producció de coneixement, la infraestructura tecnològica i les pràctiques d'extracció de dades, i que situa al centre les epistemologies marginalitzades.

Justícia ambiental: dimensió analítica que examina les càrregues ambientals desproporcionades associades a la infraestructura de la IA (extracció de recursos, consum energètic, emissions de carboni) i la seva distribució desigual entre comunitats i territoris.

Esborrament / invisibilització: absència o infrarepresentació de determinats cossos, cultures, identitats o experiències en els conjunts de dades i els sistemes d'IA, que pot perpetuar exclusions històriques.

Model fundacional: model d'IA de grans dimensions entrenat a escala amb dades àmplies i adaptat a una gran varietat de tasques posteriors (p. ex., CLIP, variants de GPT). Els models fundacionals no es classifiquen necessàriament d'alt risc segons el Reglament d'IA de la UE, però poden produir impactes socials significatius que justifiquen una avaluació estructurada.

Avaluació d'impacte sobre els drets fonamentals (FRIA): avaluació exigida per l'article 27 del Reglament d'IA de la UE als responsables del desplegament de sistemes d'IA d'alt risc, amb l'objectiu d'identificar els riscos per als drets fonamentals tal com els protegeix la Carta dels Drets Fonamentals de la Unió Europea. L'AII constitueix una contribució a la FRIA.

Interseccionalitat: marc analític, desenvolupat per Kimberlé Crenshaw i ampliat, entre d'altres, per Patricia Hill Collins i Sirma Bilge, que examina com els eixos d'opressió (gènere, raça, classe, discapacitat, sexualitat, edat, etc.) interactuen dins dels sistemes de poder i produeixen formes diferenciades i compostes de discriminació i desigualtat.

Matriu de dominació: concepte desenvolupat per Patricia Hill Collins per descriure l'organització del poder al llarg d'eixos d'opressió que s'entrecreuen i que operen simultàniament en els nivells estructural, disciplinari, hegemònic i interpersonal.

Sistema d'IA multimodal: sistema d'IA que processa i relaciona simultàniament múltiples modalitats de dades, com ara text, imatges, àudio i vídeo. Els sistemes multimodals plantegen reptes particulars per a l'avaluació d'impacte interseccional a causa de la propagació de biaixos entre modalitats.

Pregunta d'obertura / pregunta de seguiment: la matriu de l'AII organitza cada àrea d'avaluació en dos nivells: preguntes d'obertura (sí/no/NA, que responen tots els equips) que assenyalen possibles problemes, i preguntes de seguiment que guien una anàlisi més profunda quan s'han identificat problemes.

Persona / persones (subjecte per defecte): en aquestes directrius, «persones» fa referència a totes les persones titulars de drets, incloses les que no estan representades a les dades, les que no són usuàries del sistema o les que en resulten afectades indirectament. Des d'una perspectiva feminista i interseccional, una «persona» genèrica mai no és neutral: tant els sistemes d'IA com els marcs d'avaluació tendeixen a prendre un subjecte dominant com a referència per defecte. Les persones avaluadores s'haurien de preguntar qui se suposa implícitament quan es parla de «persones», «usuaris» o «el públic», i qui en queda fora.

Posicionalitat: context social i polític que conforma la perspectiva d'una persona o d'un equip, incloses les dimensions de gènere, raça, classe, disciplina i afiliació institucional. Reconèixer la posicionalitat és un requisit previ per a una pràctica reflexiva de desenvolupament de la IA.

Representació: qui apareix a les dades, com hi apareix i qui n'és absent. Les decisions de representació en els conjunts de dades i en el disseny de la IA reflecteixen i reprodueixen jerarquies socials.

Coneixement situat: concepte desenvolupat per Donna Haraway segons el qual tot coneixement es produeix des d'una posició social, cultural i històrica específica. No hi ha cap mirada neutral, «mirada des d'enlloc»; reconèixer la posicionalitat és un requisit metodològic per a la recerca feminista i interseccional.

Discriminació sistèmica: discriminació produïda i sostinguda per estructures, normes i institucions més que no pas per actes individuals aïllats. La discriminació sistèmica es pot codificar en els sistemes d'IA a través de les dades d'entrenament, els objectius del model i els contextos de desplegament.

Violència de gènere facilitada per la tecnologia: violència contra les dones i les nenes exercida, amplificada o facilitada a través de tecnologies digitals, inclòs l'assetjament sexual basat en imatges, les imatges íntimes no consentides, l'assetjament persistent (stalking) i l'assetjament en línia. L'aborda la Recomanació CM/Rec(2026)2 del Consell d'Europa sobre la rendició de comptes per la violència facilitada per la tecnologia contra les dones i les nenes.

Referències

Agarwal, S., et al. (2021). *Evaluating CLIP: Towards characterization of broader capabilities and downstream implications*. arXiv preprint.

Benjamin, R. (2019). *Race After Technology*. Polity.

Center for Data Science and Public Policy (DSaPP), University of Chicago. (2018). *Aequitas: The Bias and Fairness Audit Toolkit for Machine Learning.* Retrieved July 31, 2026, from https://dssg.github.io/aequitas/

Charter of Fundamental Rights of the European Union (2012/C 326/02). Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/treaty/char_2012/oj/eng

Crenshaw, Kimberle (1989). *Demarginalizing the Intersection of Race and Sex: A Black Feminist Critique of Antidiscrimination Doctrine, Feminist Theory and Antiracist Politics*. University of Chicago Legal Forum: Vol. 1989, Article 8. Available at: https://chicagounbound.uchicago.edu/uclf/vol1989/iss1/8

Collins, P. H., & Bilge, S. (2020). *Intersectionality* (2nd ed.). Polity Press.

Danish Institute for Human Rights. (2020). *Introduction to human rights impact assessment (HRIA Guidance and Toolbox)*. Retrieved July 31, 2026, from https://www.humanrights.dk/tools/human-rights-impact-assessment-guidance-toolbox/introduction-human-rights-impact-assessment

D'Ignazio, C., & Klein, L. (2019). *Data Feminism*. MIT Press.

European Commission, Directorate-General for Environment. (n.d.). *Environmental Impact Assessment (EIA)*. Retrieved July 31, 2026, from https://environment.ec.europa.eu/law-and-governance/environmental-assessments/environmental-impact-assessment-eia_en

European Commission, High-Level Expert Group on Artificial Intelligence. (2020). *Assessment List for Trustworthy Artificial Intelligence (ALTAI) for self-assessment*. Retrieved July 31, 2026, from https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment

European Parliament and Council of the European Union. (2016). *Regulation (EU) 2016/679 of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)*. Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/reg/2016/679/oj/eng

European Parliament and Council of the European Union. (2024). *Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Retrieved July 31, 2026, from https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng

Jääskeläinen, P., Sharma, N., Pallett, H. et al. (2025). *Intersectional analysis of visual generative AI: the case of stable diffusion*. AI & Soc 40, 4341–4362.

Hamidieh, K., Zhang, H., Gerych, W., Hartvigsen, T., & Ghassemi, M. (2024). *Identifying implicit social biases in vision-language models.* Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society.

Hausladen, C. I., Knott, M., Camerer, C. F., & Perona, P. (2025). *Social Perception of Faces in a Vision-Language Model*. Proceedings of the 2025 ACM Conference on Fairness, Accountability, and Transparency (FAccT '25).

Fairlearn. (n.d.). *Fairlearn: An open-source toolkit for assessing and improving fairness in AI*. Retrieved July 31, 2026, from https://fairlearn.org/

Leslie, D. (2019). *Understanding artificial intelligence ethics and safety: A guide for the responsible design and implementation of AI systems in the public sector*. The Alan Turing Institute. Retrieved July 31, 2026, from https://www.turing.ac.uk/news/publications/understanding-artificial-intelligence-ethics-and-safety

Observatori d'Ètica en Intel·ligència Artificial de Catalunya (OEIAC). (n.d.). *El Model PIO*. Retrieved July 31, 2026, from https://oeiac.cat/el-model/

Ovalle, A., Subramonian, A., Gautam, V., Gee, G., & Chang, K.-W. (2023). *Factoring the matrix of domination: A critical review and reimagination of intersectionality in AI fairness*. Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society.

Ruiz García, S., & Gómez Bigordà, L. (2025). *Charting Pathways: An intersectional impact assessment for vision and language foundation models*. In M. Gutiérrez Almazor & A. M. Moreno Cano (Eds.), Women, Technology, and Power: Unmasking (and Dealing with) Digital Disparities in the Times of the Platforms (pp. 225–243). Tirant Humanidades.

Treasury Board of Canada Secretariat. (2021). *Directive on Automated Decision-Making*. Retrieved July 31, 2026, from https://www.tbs-sct.canada.ca/pol/doc-eng.aspx?id=32592

UNESCO. (n.d.). *Ethical Impact Assessment*. Retrieved July 31, 2026, from https://www.unesco.org/ethics-ai/en/eia

Annex A: El marc de l'AII

L'annex A, la Matriu de l'AII, es distribueix com a document separat. Proporciona el conjunt complet de preguntes orientadores organitzades per dimensió analítica (files: Vida-Màquina, Sistèmica-Política i Mètodes-Mètriques) i per àrea del cicle de vida (columnes). Es pot començar a treballar la matriu per qualsevol àrea i utilitzar-la de manera no seqüencial.

La matriu és un complement operatiu d'aquestes directrius, no un document autònom. S'ha d'utilitzar conjuntament amb la secció 3 d'aquest document, que explica com navegar per la matriu, interpretar-ne els resultats i traduir les conclusions en decisions concretes.

Accediu-hi aquí:

https://nextcloud.alia.cat/index.php/s/H8d35REBtc9z4ct

Autoria i agraïments

Aquestes directrius s'han elaborat en el marc del projecte InterVisions. L'autoria correspon conjuntament a les entitats sòcies del consorci i al Grup de Treball de les Directrius, que van redactar i desenvolupar plegades el contingut. Més avall s'agraeix separadament al Consell Assessor la seva revisió, les seves aportacions i el seu acompanyament durant tot el procés.

D'acord amb el nostre compromís amb la reflexivitat crítica, les autores i autors reconeixen la seva pròpia posició dins de les relacions de poder examinades en aquest informe, així com la manera en què les seves trajectòries disciplinàries i experiències viscudes han modelat el seu disseny i interpretació, mantenint-se conscients d'aquestes dinàmiques mitjançant una pràctica reflexiva continuada (Klumbytė, Draude, & Taylor, 2022; Civic, 2022).

Autoria

Consorci

ALIA-Donestech:
Eva Cruells López, Mireia Orra i De Salsas

Computer Vision Center (CVC):
Lluís Gómez i Bigordà, Sofia Llàcer Caro

Diputació de Barcelona:
Sonia Ruiz García

Grup de Treball de les Directrius

Maya Aidlin-Perlman
Marta Cruells López
Nadia Nadesan
Adrià Molina Rodríguez
Margarita Padilla García

Agraïments

Les autores i autors agraeixen sincerament als membres del Consell Assessor la seva revisió crítica i el seu acompanyament en l'elaboració d'aquestes directrius, sense que n'assumeixin la responsabilitat de l'autoria del text:

Consell Assessor

Yuki M. Asano
Sara Aguilar Ricart
Alex Cadon
Alba Elvira Guiral
Dimosthenis Karatzas
Laura Martín Montañez
Marisa Molina Alonso
Ana Paricio
PhD, Graziella Piga
H. Titilola Olojede
Dra. Núria Vergés Bosch

INTER VISIONS



Co-funded by
the European Union